



APOGÉE INVEST

RAPPORT D'INVESTISSEMENT

Stratégie FX

Multi-Moteurs

Quatre moteurs de rendement quasi orthogonaux

Recherche 2019–2026, exécution mesurée sous MetaTrader 5,
tests de résistance, rejou de scénarios et conditions de déploiement

Préparé par	Thomas Vaudescal
Pour	Apogée Invest
Date	27 juillet 2026
Statut	Prêt pour déploiement contrôlé
Version	2.0

Confidentiel. Ce document présente une stratégie quantitative sur le marché des changes à l'intention exclusive d'Apogée Invest. Les performances indiquées sont issues de *backtests* sur données historiques et de simulations de résistance. Les performances passées ne préjugent pas des performances futures.

Table des matières

1	Résumé exécutif	1
2	Mandat d'investissement et philosophie	3
2.1	Mandat	4
2.2	Problème adressé	4
2.3	Architecture du portefeuille	5
2.4	Pourquoi quatre moteurs	5
3	Cadre méthodologique	6
3.1	Moteur de backtest	6
3.2	Sources de données	7
3.3	Découpage in-sample et hors échantillon	7
3.4	Contrôle anti look-ahead	7
4	Moteur 1 — Mean Reversion Intraday Filtré (67 %)	8
4.1	Intuition économique	8
4.2	Mécanique du signal	8
4.3	Performance historique	9
4.4	Exemples de trades réels	10
5	Moteur 2 — Momentum Journalier Multi-Paires (9 %)	10
5.1	Intuition économique	10
5.2	Mécanique du signal	11
5.3	Justification du choix des trois paires	11
5.4	Performance historique	11
5.5	Épisodes représentatifs	12
6	Moteur 3 — Mean Reversion Journalière par RSI (9 %)	13
6.1	Intuition économique	13
6.2	Mécanique du signal	13
6.3	Le paradoxe du Sharpe standalone	13
6.4	Performance historique	14
6.5	Épisodes représentatifs	14
7	Moteur 4 — Momentum Multi-Actifs (15 %)	15
7.1	Pourquoi ce moteur, et pourquoi trois instruments	16
7.2	Mécanique du signal	16
7.3	Du signal à la taille de position	17
7.4	Dimensionnement progressif : ce qui a été testé, et pourquoi il est écarté	18
7.5	Performance historique	24

7.6	Épisodes représentatifs	24
7.7	Ce que ce moteur doit à sa période	25
8	Recherche et exécution : deux mesures, un seul compte	26
8.1	Le mot « levier » ne désigne pas la même quantité	26
8.2	Comment l'échelle a été calibrée	26
8.3	Ce qu'il faut en retenir pour lire ce document	27
9	Architecture de pondération et gestion du risque	27
9.1	Allocation statique 67 / 9 / 9 / 15	27
9.2	Couche de ciblage de volatilité	28
9.3	Impact du levier sur les métriques	29
9.4	Protection drawdown — disponible, désactivée, et non remplacée	30
10	Performance de recherche in-sample	31
10.1	Métriques agrégées	31
10.2	Validation par fenêtres annuelles (walk-forward)	32
10.3	Heatmap des rendements mensuels	33
10.4	Courbe <i>underwater</i> du drawdown	33
10.5	Sharpe glissant sur 63 jours	33
10.6	Corrélations glissantes entre moteurs	33
10.7	Contribution mensuelle par moteur	33
11	Validation hors échantillon	33
11.1	Comparaison directe	34
11.2	Zoom sur la fenêtre de validation	35
11.3	Caveat méthodologique sur le caractère OOS	35
12	Tests de résistance — bootstrap historique	38
12.1	Méthodologie	38
12.2	Résultats	38
12.3	Interprétations critiques	38
12.4	Stabilité face aux hyperparamètres de ciblage de volatilité	38
13	Robustesse statistique avancée	39
13.1	Pourquoi un Sharpe ponctuel ne suffit pas	39
13.2	Intervalle de confiance bootstrap sur les métriques	40
13.3	<i>Equity fan chart</i> — trajectoires bootstrap alternatives	42
13.4	Tests d' <i>overfitting</i>	42
13.5	Tests de supériorité prédictive	46
13.6	Stabilité temporelle multi-métrique	47
13.7	Verdict consolidé	48
14	Rejeu de scénarios historiques	49
14.1	Lecture détaillée des six scénarios	49
14.2	Observations transversales	50
15	Analyse des risques et limites méthodologiques	50
15.1	Avertissement 1 — Le résultat repose sur un seul moteur, et davantage qu'avant	51

15.2	Avertissement 2 — La sélection a consommé du pouvoir statistique	52
15.3	Avertissement 3 — Aucun coupe-circuit n'est actif	52
15.4	Avertissement 4 — Le dimensionnement multiplie le risque autant que le rendement	53
15.5	Avertissement 5 — Coûts de transaction au niveau portefeuille	53
15.6	Avertissement 6 — Hyperparamètres des sub-stratégies	53
15.7	Tableau récapitulatif des risques	54
16	Conditions de déploiement	54
16.1	Décisionnaires et responsabilités	55
A	Annexe A — Glossaire des termes techniques	55
B	Annexe B — Anatomie d'un trade	57
C	Sensibilité à l'allocation du trio FX	58
C.1	La question posée	58
C.2	Méthodologie succincte	59
C.3	Comparaison d'allocations nommées	59
C.4	Balayage 1D — part MR de 0 % à 100 %	60
C.5	Carte ternaire du simplex complet	61
C.6	Frontière efficiente empirique Vol × CAGR	62
D	Principes méthodologiques du <i>robustness report</i>	63
D.1	Le problème général — pourquoi un Sharpe ponctuel est insuffisant	64
D.2	Block bootstrap stationnaire (Politis–Romano 1994)	64
D.3	Probabilistic Sharpe Ratio (Bailey–López de Prado 2012)	65
D.4	Deflated Sharpe Ratio (Bailey–López de Prado 2014)	65
D.5	Haircut Sharpe Ratio (Harvey–Liu 2015)	66
D.6	Minimum Backtest Length (Bailey et al. 2014)	66
D.7	Probability of Backtest Overfitting via CSCV (Bailey et al. 2015)	67
D.8	Hansen SPA (2005) et Romano–Wolf StepM (2005)	68
D.9	Stratégie de combinaison — quelle hiérarchie de tests ?	68

1 Résumé exécutif

La **Stratégie FX Multi-Moteurs** est un portefeuille quantitatif qui combine quatre moteurs de rendement structurellement indépendants : une composante de *retour à la moyenne* intraday filtrée par un régime macroéconomique, une composante de *suivi de tendance* journalier sur trois paires, une composante de *retour à la moyenne* journalier sur l'indicateur RSI, et une composante de *suivi de tendance* sur trois instruments directionnels (or, dollar-yen, argent). L'ensemble est piloté par une couche unifiée de ciblage de volatilité.

Le mandat retenu vise un rendement annualisé de l'ordre de **40 %**. Le plafond de drawdown qui figurait dans les versions antérieures de ce document a été **retiré à la demande du mandant** : le risque n'est plus une contrainte du programme, il en est une conséquence mesurée. Ce document énonce donc ce que ce niveau d'ambition coûte en repli, sans l'atténuer.

Les chiffres qui font foi viennent du moteur qui exécute

Deux moteurs mesurent ce portefeuille et ils ne mesurent pas la même chose. Le moteur de recherche (**vectorbtpro**) applique un levier au poids de position ; le moteur d'exécution (MetaTrader 5) ouvre un notionnel borné par la distance au stop. Les chiffres publiés ici sont ceux de MetaTrader 5, parce que c'est lui qui passe les ordres. Les métriques de recherche restent en annexe de robustesse, où elles servent à éprouver la structure de la stratégie, pas à annoncer une performance.

Tab. 1. Résultats du portefeuille de production dans le testeur MetaTrader 5 sur EURUSD.c, 2021-01-01 à 2026-04-29. Ce sont les chiffres qui font foi : ils proviennent du moteur qui exécute réellement les ordres, avec le spread du courtier, l'arrondi des lots et les frais de portage.

Métrique	Valeur
Profit net	\$49,143 (dépôt \$10,000)
CAGR	39.65 %
Sharpe (MetaTrader 5)	1.01
Drawdown d'équité maximal	47.04 %
Facteur de profit	2.18
Nombre de transactions	905

Idée clé

Le résultat est concentré, et c'est le fait le plus important du document. La sleeve momentum — or, dollar-yen et argent, équipondérés — représente 15 % de l'allocation et 87,0 % du résultat net, pour 89 transactions sur 905. À l'intérieur de cette sleeve, **une position unique sur l'argent apporte 46,6 % du résultat net du portefeuille**, et les trois plus grosses en apportent 80 %. La performance annoncée dépend donc d'un très petit nombre de mouvements, sur une période exceptionnellement favorable aux tendances des métaux et du yen. Aucune moyenne, aucun ratio de Sharpe ne rend visible cette dépendance — la section 15 en tire les conséquences.

Le poids de cette sleeve a été réduit le 28 juillet 2026, de 20 % à 15 % : le test de sur-ajustement appliqué à la grille d'allocations échoue (section 13), ce qui indique que




Fig. 1. Solde du compte simulé dans le testeur MetaTrader 5, dépôt initial de 10 000 USD, sur la totalité des données disponibles. La courbe intègre le spread du courtier, l'arrondi des lots et les frais de portage.

le poids le mieux classé sur une moitié des données ne se transporte pas sur l'autre. La conséquence était écrite avant le calcul.

Tab. 2. Décomposition du résultat par sleeve. « Gold Momentum » en concentre 87,0 % pour 89 transactions : le résultat du portefeuille dépend d'un petit nombre de positions, ce qu'aucune moyenne ne montre.

Sleeve	Transactions	Résultat net	Part	Taux de gain
Gold Momentum	89	\$42,755	87,0 %	41,6 %
TS Momentum	479	\$3,613	7,4 %	62,8 %
MR Macro	304	\$1,515	3,1 %	57,9 %
RSI Daily	33	\$1,261	2,6 %	66,7 %

Quatre conclusions pour la décision

1. **Le mandat de rendement est tenu** sur la période mesurée : 39,7 % de croissance annualisée, pour un profit net de 47 953 USD sur un dépôt de 10 000 USD.
2. **Le repli maximal d'équité atteint 47,0 %.** C'est le prix direct du niveau de risque choisi : le dimensionnement des positions a été calibré pour atteindre la cible de rendement, et il multiplie le risque dans la même proportion.
3. **La performance repose sur une sleeve.** Retirer la sleeve momentum ramènerait le résultat à moins d'un dixième de son niveau. La diversification annoncée par l'architecture à quatre moteurs ne s'est pas traduite par une diversification du résultat.

4. **Une année sur six est négative** (2023, $-13,1\%$), et le repli d'équité dépasse celui du solde sur toute la période — signe que des positions restent longtemps ouvertes en territoire défavorable.

Tab. 3. *Résultat par année civile, mesuré sur le solde du compte. Le repli indiqué est celui du solde : il ne descend pas aussi bas que le repli d'équité, qui compte aussi les positions encore ouvertes.*

Année	Solde de fin	Rendement	Repli maximal	Transactions
2021	\$10,408	4.1 %	-5.3 %	97
2022	\$16,759	61.0 %	-3.7 %	199
2023	\$15,402	-8.1 %	-15.6 %	203
2024	\$19,827	28.7 %	-13.0 %	181
2025	\$27,529	38.8 %	-7.4 %	174
2026	\$59,143	114.8 %	-13.3 %	51

Les sections suivantes développent le mandat, l'architecture du portefeuille, les quatre moteurs de rendement, la couche de risque, les résultats de recherche avec leurs tests de robustesse, l'écart entre recherche et exécution, et les conditions de déploiement.

2 Mandat d'investissement et philosophie

2.1 Mandat

Univers d'investissement	Paires de devises majeures : EUR-USD, GBP-USD, USD-JPY, USD-CAD, plus les deux métaux précieux : l'or (XAU-USD) et l'argent (XAG-USD). Pas d'exposition aux devises émergentes, aux <i>crosses</i> exotiques ni aux dérivés structurés.
Objectif de rendement	CAGR cible de l'ordre de 40 % annualisés.
Contrainte de risque	Aucune. Le plafond de drawdown de 35 % des versions antérieures a été retiré sur instruction du mandant, qui a déclaré le risque non contraignant. Le repli est mesuré et rapporté, il ne borne pas le dimensionnement.
Horizon	Multi-annuel (minimum 3 ans recommandé pour réalisation statistique des métriques).
Cadre réglementaire	L'exécution suppose un compte autorisant le levier requis par le dimensionnement retenu. La compatibilité avec les plafonds ESMA retail (30× sur majors G10) doit être vérifiée auprès du courtier avant tout déploiement.
Réserve de capital	À dimensionner sur le repli d'équité constaté (47,0 %), et non sur un plafond contractuel qui n'existe plus.
Rebalancement	Quotidien, sans adaptation de régime. Pas de réallocation discrétionnaire.
Liquidité	Positions entièrement liquidables sous 24 heures.
Statut actuel	Prêt pour déploiement contrôlé en <i>paper-trade</i> . Go-live conditionné à la validation de la check-list de production (section 16).

Idée clé

Ce mandat a changé de nature. Les versions antérieures de ce document visaient 10 à 15 % de rendement sous un plafond de repli de 35 % : l'objectif était la régularité. Le mandat actuel vise 40 % sans contrainte de repli. Ce n'est pas le même produit, et les deux ne se comparent pas. Tout ce qui suit décrit le second.

2.2 Problème adressé

Le marché des changes est simultanément l'un des plus liquides et l'un des plus difficiles à battre systématiquement. Chaque signal pris isolément est dominé par un bruit important, et les *edges* individuels tendent à s'éroder rapidement lorsqu'ils sont répliqués par d'autres acteurs. La réponse classique à ce problème — empiler plusieurs signaux indépendants pour réduire la variance du portefeuille agrégé — n'est efficace qu'à une condition stricte : les signaux doivent être **vraiment orthogonaux** les uns aux autres. Or, la plupart des stratégies FX publiées sont en réalité fortement corrélées parce qu'elles exploitent la même source d'alpha sous-jacente (*carry*, tendance EMA, *mean reversion* RSI).

Thèse économique

L'ambition de la Stratégie FX Multi-Moteurs est d'assembler des moteurs de rendement qui capturent des **sources d'alpha structurellement différentes**, de sorte que leur combinaison porte le rendement visé sans concentrer le risque sur un seul régime de marché. La section 15 montre dans quelle mesure cette ambition est tenue — et dans quelle mesure elle ne l'est pas.

2.3 Architecture du portefeuille




Fig. 2. Architecture à quatre moteurs de la Stratégie FX Multi-Moteurs. Allocation statique, puis couche de ciblage de volatilité, puis pipeline d'équité finale. Les 5 points de capital transférés à la sleeve momentum ont été pris sur la seule Mean Reversion Intraday : les poids absolus du Momentum Journalier et du RSI Journalier sont inchangés, si bien que le trio FX répartit entre ses membres les 85 % qui lui restent selon les ratios 79/11/11.

2.4 Pourquoi quatre moteurs

- **Deux moteurs ne suffisent pas** : les analyses d'attribution montrent qu'une combinaison à deux moteurs (Mean Reversion Intraday + Momentum Journalier) laisse les années 2019 et 2023 en territoire négatif.
- **Le trio FX seul plafonne** : sa combinaison non levierée rend 2,2 % pour une volatilité de 5,8 %. Poussé par le ciblage de volatilité, son rendement culmine autour de 32 % avant que le *drag* de variance ne le fasse retomber. Le mandat de 40 % lui était donc inaccessible, quel que soit le levier.
- **La sleeve momentum lève cette contrainte parce qu'elle est quasi orthogonale au trio** : à 15 % de poids, elle porte le Sharpe du combiné de 0,66 à environ 1,0 (tableau 15), ce qui déplace le plafond de rendement au-delà de la cible. La cible devient atteignable à un niveau de volatilité *inférieure* à celui qu'exigeait le trio seul.
- **Trois instruments plutôt qu'un depuis juillet 2026** : la sleeve applique le même signal de tendance à l'or, au dollar-yen et à l'argent, chacun recevant un tiers du budget. L'argent, médiocre pris isolément, casse la dépendance du portefeuille à la seule trajectoire de l'or ; le dollar-yen y ajoute un *carry* de portage positif, alors que l'or coûte des frais de portage.

Le poids de cette sleeve, d'abord fixé à 20 %, a été ramené à 15 % le 28 juillet 2026 après échec du test de sur-ajustement portant sur la grille d'allocations (section 13).

- **Un cinquième signal a été évalué et retiré** : une composante *cross-section momentum*, qui classe les instruments les uns contre les autres au lieu de suivre la tendance de chacun. Son meilleur panier atteint un Sharpe de 0,609 pour une corrélation de 0,66 au panier de tendance existant — additif en théorie de portefeuille (le seuil d'additivité est à 0,565), mais de justesse, et en-dessous du panier qu'il devrait compléter (0,856). Sa variante long-short a été écartée pour une raison d'exécution : elle traite près de sept fois plus souvent que la production, et son avance mesurée en recherche ne survit à aucun des scénarios de coût réel mesurés sur ce portefeuille.
- **Un signal intraday horaire a été construit, testé et abandonné** : son Sharpe autonome dans le simulateur d'exécution est de -3,98, très en-dessous du seuil de 0,5 fixé *avant* le test. Le code reste compilé dans le programme livré, à poids nul.

Idée clé

La leçon principale de la recherche préparatoire : un moteur avec un Sharpe standalone modeste peut être le meilleur diversificateur si sa corrélation avec le reste du portefeuille est négative pendant les années difficiles. Ce qui compte n'est pas le Sharpe individuel mais la **contribution marginale au Sharpe du portefeuille**, qui dépend de la corrélation. Un signal à Sharpe 0.16 anti-corrélé bat souvent un signal à Sharpe 0.60 corrélé.

Idée clé

Le revers de cette leçon apparaît à l'exécution. L'orthogonalité qui justifie l'entrée de la sleeve momentum explique aussi qu'elle porte, à elle seule, 87,0 % du résultat du portefeuille sur la période mesurée : la diversification a servi à *autoriser* le rendement visé, pas à le répartir. Le passage de l'or seul au trio d'instruments a diversifié la sleeve, pas le portefeuille. Voir la section 15.

3 Cadre méthodologique

3.1 Moteur de backtest

L'ensemble des calculs repose sur un moteur de backtest vectorisé de qualité institutionnelle, capable de traiter les grilles de recherche à l'échelle de la minute (environ trois millions de barres par paire). Les portefeuilles sont calculés avec partage de cash entre paires, de sorte que le levier reflète l'exposition agrégée et non la somme naïve des positions individuelles.

L'exécution simulée est délibérément conservatrice : slippage de 15 points de base sur les stratégies intraday, 10 points de base sur les stratégies journalières, fees de 5 points de base par trade. Ces hypothèses sont plus sévères que ce qu'un broker retail moderne applique en production.

3.2 Sources de données

Source	Fréquence	Usage
EUR-USD, GBP-USD, USD-JPY, USD-CAD	minute	Moteur 1 (close et VWAP intraday)
Idem, resamplées	journalière	Moteurs 2 et 3 (signaux EMA et RSI)
XAU-USD, USD-JPY, XAG-USD	journalière	Moteur 4 (tendance multi-horizons)
Spread 10Y–2Y des bons du Trésor US	journalière	Filtre macro du Moteur 1
Taux de chômage US	mensuelle	Filtre macro du Moteur 1

Les séries FX minute sont strictement intersectées entre les paires (pas de *forward-fill*), ce qui garantit l’absence de biais silencieux dû à un *gap* sur une paire unique.

3.3 Découpage in-sample et hors échantillon

- **In-sample** : du 1^{er} avril 2019 au 1^{er} avril 2025. Période utilisée pour le design de la stratégie, la sélection des paires, l’allocation et le tuning des hyperparamètres.
- **Hors échantillon (OOS)** : du 1^{er} avril 2025 au 1^{er} avril 2026. Période réservée à la validation, jamais utilisée pendant le design.

Avertissement

Point de transparence sur le caractère de l’OOS : la fenêtre hors échantillon est un découpage *ex-post*, effectué lorsque les données 2025-04 et postérieures sont devenues disponibles. Il ne s’agit donc pas d’un véritable *holdout* pré-engagé avant le design. Malgré cette limite, le résultat reste significatif parce que le Sharpe OOS est strictement supérieur à l’in-sample (3.02 contre 0.75) — un surajustement authentique produirait systématiquement une dégradation hors période de conception, pas une amélioration.

3.4 Contrôle anti look-ahead

Une discipline anti look-ahead est appliquée systématiquement à trois niveaux :

1. **Au niveau de chaque signal individuel** : chaque indicateur (EMA, RSI, Bollinger Bands) est lagué d’un bar par rapport à sa consommation, de sorte que le signal à l’instant *t* n’utilise que l’information strictement disponible avant *t*.
2. **Au niveau du filtre macro** : le taux de chômage, publié le premier vendredi du mois suivant, est propagé dans le temps en respectant sa date de publication réelle. Le spread de courbe des taux est quotidien et ne nécessite pas de lag supplémentaire.
3. **Au niveau du ciblage de volatilité** : le levier appliqué à l’instant *t* utilise uniquement les volatilités réalisées strictement antérieures à *t*.

Cette discipline est validée par des tests automatisés qui vérifient, pour chaque signal, que décaler les returns futurs d’un jour ne modifie pas les trades du backtest — un test standard de non-contamination. La reproductibilité numérique du pipeline est garantie par un test de référence qui détecte immédiatement toute dérive des résultats.

4 Moteur 1 — Mean Reversion Intraday Filtré (67 %)

Le premier moteur reçoit la part prépondérante de l'allocation statique : 67 %. Ce poids est justifié par le fait qu'il possède simultanément le Sharpe le plus élevé parmi les moteurs FX et la volatilité intrinsèque la plus basse. Les deux autres composantes FX jouent un rôle de diversificateurs à 9 % chacune, et leur valeur apparaît surtout dans les années où ce premier moteur est dormant ; la sleeve momentum complète l'ensemble à 15 %, cinq points nets lui ayant été transférés depuis ce moteur en juillet 2026 — dix d'abord, dont cinq ont été rendus après l'échec du test de sur-ajustement (section 13).

Idée clé

Le poids ne dit rien du résultat. Ce moteur porte 67 % de l'allocation et 3,1 % du résultat mesuré à l'exécution. Un poids d'allocation dimensionne une exposition ; il ne prédit pas la contribution au profit, qui dépend de ce que le marché a offert à chaque signal sur la période.

4.1 Intuition économique

Thèse économique

La *mean reversion* intraday fonctionne dans les régimes de liquidité normale et de transmission monétaire saine. Lorsque la courbe des taux s'inverse ou que le taux de chômage commence à remonter, les micro-structures qui rendent la *mean reversion* profitable disparaissent : les flux deviennent unidirectionnels en raison de la *fuite vers la qualité*, les spreads s'élargissent, et toute prise de position à contre-courant devient coûteuse. Le filtre macro bloque précisément la stratégie dans ces régimes.

Techniquement, la stratégie exploite deux asymétries micro-structurelles bien documentées dans la littérature académique sur le marché FX :

1. La tendance des prix intraday à revenir vers le **VWAP** (*Volume-Weighted Average Price*) au cours de la session de chevauchement Londres + New York, période durant laquelle les teneurs de marché rebalancent leurs inventaires.
2. La **surréaction de court terme** aux annonces : les déviations supérieures à cinq écarts-types autour du VWAP capturent typiquement une réaction excessive à une publication économique ou à un flux institutionnel concentré.

4.2 Mécanique du signal

1. **VWAP ancré à la journée** : le calcul est réinitialisé à 00h00 UTC chaque jour, et reprend de façon cumulative.
2. **Bandes de Bollinger** à 80 périodes et 5 écarts-types, calculées sur la déviation prix moins VWAP. Les bandes ainsi obtenues définissent des seuils dynamiques de retour à la moyenne.
3. **Filtre session** : uniquement entre 8h et 16h UTC, correspondant au chevauchement Londres et New York où la liquidité atteint son maximum.
4. **Filtre macro à deux étages** :
 - Spread de courbe des taux 10 ans moins 2 ans inférieur à 0.5 (proxy de stress cyclique) ;
 - Taux de chômage dont la variation sur trois mois n'est pas haussière (proxy d'absence de fin de cycle d'expansion).

5. **Règles d'entrée** : position longue si le prix touche la bande inférieure, position courte si le prix touche la bande supérieure, sous réserve que les filtres session et macro soient tous deux passants.
6. **Règles de sortie** : stop-loss à -0.5% , take-profit à $+0.6\%$, arrêt forcé à 21h UTC, durée maximale de détention six heures.

4.3 Performance historique




Fig. 3. Équité et drawdown du Moteur 1 pris isolément sur la période 2019–2026 (non pondéré, non leveragé). La ligne verticale pointillée marque le début de la fenêtre hors échantillon.

Tab. 4. Performance annuelle du Moteur 1 pris isolément. L'année 2021 ne produit aucun trade parce que le spread 10Y–2Y est resté supérieur à 0.5 toute l'année post-Covid, déclenchant le filtre macro.

Année	Trades	CAGR	Sharpe	Max DD
2019	44	-0.82%	-0.64	-1.71%
2020	3	$+0.69\%$	$+1.19$	-0.02%
2021	0	0.00%	0.00	0.00%
2022	30	$+5.21\%$	$+2.23$	-0.67%
2023	19	-0.38%	-0.28	-1.22%
2024	19	$+2.31\%$	$+2.08$	-0.34%
2025	11	$+0.85\%$	$+0.72$	-0.71%

Avertissement

Le filtre macro peut réduire la stratégie au silence complet. En 2021, aucun trade n'a été déclenché parce que la courbe des taux restait exceptionnellement raide après le choc Covid. Ce comportement est voulu : les tests de sensibilité ont montré que relâcher le seuil à 0.7 ou plus détruit le Sharpe de l'année 2025 (passage de +0.72 à -0.38). Le *silence sélectif* est une propriété désirable du filtre, pas un bug.

4.4 Exemples de trades réels

Tab. 5. Exemples de trades MR Macro sur EUR-USD — deux meilleurs, un médian, deux pires. La colonne *Durée* illustre le design intraday : la position est dénouée dans la séance.

Entrée	Sortie	Sens	Durée	Rendement	P&L
2025-03-06 08 :17	2025-03-06 13 :42	Short	5.4 h	0.57 %	\$6,121
2025-02-13 13 :41	2025-02-13 17 :25	Long	3.7 h	0.57 %	\$6,083
2022-08-17 14 :04	2022-08-17 20 :04	Short	6.0 h	0.10 %	\$1,016
2024-12-18 14 :01	2024-12-18 14 :39	Long	0.6 h	-0.53 %	\$-5,658
2025-01-20 08 :31	2025-01-20 08 :35	Short	0.1 h	-0.53 %	\$-5,673

Exemple concret

Anatomie d'un trade gagnant : le trade long du 12 février 2025 à 08h31 UTC est entré lorsque le *close* EUR-USD a touché la bande inférieure calculée sur la déviation au VWAP. La session étant ouverte (08h31 tombe dans la fenêtre 8h–16h UTC) et le spread 10Y–2Y à 0.32 (sous le seuil 0.5), les deux filtres étaient passants. Le retour du prix vers le VWAP a déclenché la sortie par take-profit à 11h59 UTC, pour une durée totale de 3 heures 30 et un rendement de +0.57 %, soit un P&L de 6 236 USD sur un capital nominal d'un million.

5 Moteur 2 — Momentum Journalier Multi-Paires (9 %)**5.1 Intuition économique****Thèse économique**

Les divergences de politique monétaire entre grandes banques centrales créent des tendances FX durables. Lorsque la BCE et la Fed divergent — l'une en cycle de hausse, l'autre en pause ou en baisse — le différentiel de taux d'intérêt attendu se traduit par un mouvement directionnel du taux de change. Ce mouvement est lent, déployé sur plusieurs semaines, et capturable par un signal de tendance simple fondé sur un croisement de moyennes mobiles exponentielles, combiné à une confirmation par l'indicateur RSI.

Trois mécanismes économiques bien documentés sous-tendent ce signal :

- **Forward guidance asymétrique :** lorsqu'une banque centrale télégraphie un cycle de hausse prolongé, le marché prend plusieurs semaines à intégrer l'ensemble de la trajectoire anticipée, créant une tendance lente et exploitable.

- **Carry roll-down** : le différentiel de taux courts induit un flux d'investissement directionnel (*carry trade*) qui renforce la tendance initiée par le signal de taux.
- **Rebalancement des réserves** : les banques centrales de pays émergents rebalancent leurs réserves de change en fonction du niveau relatif de USD, EUR et JPY, créant des flux acheteurs ou vendeurs prévisibles à fréquence mensuelle.

5.2 Mécanique du signal

1. **Moyennes mobiles exponentielles EMA 20 et EMA 50** sur le close journalier de chaque paire.
2. **Indicateur RSI à 7 périodes** comme filtre de confirmation :
 - Long si $EMA_{fast} > EMA_{slow}$ et $RSI < 60$;
 - Short si $EMA_{fast} < EMA_{slow}$ et $RSI > 40$.
3. **Anti look-ahead strict** : le signal à l'instant t utilise les moyennes et le RSI calculés sur les clôtures jusqu'à $t - 1$ inclus.
4. **Ciblage de volatilité par paire** à 10 % annualisé, avec un plafond de levier individuel à $3\times$.
5. **Portefeuille du moteur** : moyenne *equal-weight* des trois paires retenues (EUR-USD, GBP-USD, USD-JPY).

5.3 Justification du choix des trois paires

La décomposition de la performance pair par pair sur la période 2019–2026 révèle que USD-CAD est le pire contributeur six années sur huit, avec des pertes importantes y compris lors des meilleures années des autres paires :

Année	EUR-USD	GBP-USD	USD-JPY	USD-CAD
2019	−3.36 %	+3.22 %	+1.67 %	−8.94 %
2022	+12.17 %	+12.90 %	+2.58 %	−7.32 %
2023	−2.57 %	+12.52 %	+6.20 %	−5.72 %

Retirer USD-CAD du Moteur 2 augmente son Sharpe de 0.44 à 0.57, soit un gain relatif de 30 %, sans dégrader le drawdown maximal qui reste autour de −12 %. L'explication retenue : le signal $EMA_{20/50} + RSI(7)$ est mal adapté à la microstructure de USD-CAD, qui est fortement *range-bound* autour du prix du pétrole WTI et présente peu de tendances exploitables. Un indicateur de tendance simple n'y trouve pas de signal net.

5.4 Performance historique

- **Rendement total full-period** : +35.70 %
- **Sharpe standalone** : 0.57
- **Max Drawdown** : −11.76 %
- **Sharpe sur la fenêtre hors échantillon** : 1.26 (*moteur principal de la performance hors échantillon*)




Fig. 4. Équité et drawdown du Moteur 2 (trois paires EUR-USD, GBP-USD, USD-JPY) pris isolément sur 2019–2026 (non pondéré, non levragé — avant application des poids 67/9/9/15 et du ciblage de volatilité global). La ligne verticale pointillée marque le début de la fenêtre hors échantillon.

5.5 Épisodes représentatifs

Tab. 6. Épisodes représentatifs du sleeve TS Momentum 3-pair — agrégats de journées consécutives de même signe de rendement. Les épisodes longs correspondent aux tendances EUR-USD / GBP-USD / USD-JPY captées par EMA 20/50.

Entrée	Sortie	Sens	Durée	Rendement
2025-04-08	2025-04-10	Long	3 j	3.20 %
2023-12-11	2023-12-14	Long	4 j	2.89 %
2020-01-19	2020-01-20	Long	2 j	0.11 %
2024-09-29	2024-10-04	Short	6 j	-2.72 %
2021-06-15	2021-06-18	Short	4 j	-2.76 %

Idée clé

Le Moteur 2 est le contributeur principal de la performance hors échantillon. Sur la fenêtre de validation 2025-04 à 2026-04, ce moteur produit un Sharpe de 1.26, bien au-dessus de son Sharpe full-period de 0.57. Cela suggère que les régimes récents sont particulièrement favorables aux tendances FX structurelles — ce qui confirme l'intérêt de maintenir un moteur de suivi de tendance dans le portefeuille, même lorsque son Sharpe standalone in-sample paraît modeste.

6 Moteur 3 — Mean Reversion Journalière par RSI (9 %)

6.1 Intuition économique

Thèse économique

Un mouvement directionnel exacerbé sur une journée est un *overshoot statistiquement rare*. Lorsque l'indicateur RSI journalier d'une paire FX majeure dépasse 75 (sur-achat) ou descend sous 25 (sur-vente), il reflète une accumulation disproportionnée de flux dans une seule direction — généralement déclenchée par une annonce macroéconomique ou un *squeeze* technique. L'expérience empirique montre que ces extrêmes se résolvent typiquement en 2 à 10 jours par un retour du prix vers un RSI neutre autour de 50.

Ce moteur exploite *exactement le régime opposé* à celui du Moteur 2 : là où le suivi de tendance capture les mouvements lents déployés sur plusieurs semaines, le RSI journalier capture les excès de court terme. D'où la corrélation négative observée (-0.251 sur la période complète) entre ces deux composantes, qui est le levier central de la diversification du portefeuille.

6.2 Mécanique du signal

1. **Calcul du RSI(14)** sur le close journalier de chaque paire.
2. **Règles d'entrée :**
 - Long si $RSI < 25$ (sur-vente) ;
 - Short si $RSI > 75$ (sur-achat).
3. **Règle de sortie :** retour à un niveau neutre $RSI \approx 50$ ou inversion du signal.
4. **Portefeuille du moteur :** moyenne *equal-weight* des trois paires EUR-USD, GBP-USD, USD-CAD.

Remarque importante : contrairement au Moteur 2, USD-CAD est **conservé** ici, tandis qu'USD-JPY en a été retiré. La microstructure *range-bound* qui handicape le momentum sur cette paire est précisément ce qui avantage un signal de retour à la moyenne. Un même défaut peut être une qualité dans un autre contexte stratégique.

6.3 Le paradoxe du Sharpe standalone

Avertissement

Le Moteur 3 a un Sharpe standalone de seulement 0.16 sur la période complète. C'est le plus faible des quatre. Pourtant, son retrait ferait perdre environ 30 % du Sharpe du portefeuille combiné — la définition exacte d'un diversificateur anti-corrélé de valeur.

La décomposition année par année révèle le mécanisme :

Année	Moteur 3	Moteur 1	Moteur 2	Commentaire
2019	+0.95★	−0.64	−0.41	Le Moteur 3 sauve l'année
2020	−0.03	+1.19	−0.24	—
2021	+0.61	0.00	+0.62	—
2022	−0.51	+2.23	+1.18	—
2023	+0.92★	−0.28	+0.55	Le Moteur 3 sauve l'année
2024	−0.24	+2.08	+0.61	—
2025	+0.38	+0.72	+1.57	—
2026 YTD	+3.54★	+1.72	−1.59	Le Moteur 3 sauve le YTD

Le Moteur 3 est positif exactement dans les années où les deux autres perdent. C'est un diversificateur anti-corrélé au sens strict. La matrice de corrélation sur la période complète confirme :

	Moteur 1	Moteur 2	Moteur 3
Moteur 1	1.000	+0.056	−0.027
Moteur 2	+0.056	1.000	−0.251
Moteur 3	−0.027	−0.251	1.000

6.4 Performance historique

6.5 Épisodes représentatifs

Tab. 7. Épisodes représentatifs du sleeve RSI Daily 3-pair. Les épisodes courts typiques (2-10 jours) reflètent les retours rapides après sur-achat/sur-vente capturés par RSI(14).

Entrée	Sortie	Sens	Durée	Rendement
2020-03-24	2020-03-27	Long	4 j	48.49 %
2022-09-28	2022-09-29	Long	2 j	29.36 %
2019-05-22	2019-05-23	Short	2 j	−0.18 %
2022-09-20	2022-09-23	Short	4 j	−19.72 %
2020-03-16	2020-03-18	Short	3 j	−46.73 %

Idée clé

La leçon de construction de portefeuille : un moteur à Sharpe individuel faible peut être le meilleur diversificateur si sa corrélation avec le reste est négative sur les années difficiles. Ce qui compte pour le portefeuille global n'est pas le Sharpe individuel mais la **contribution marginale au Sharpe combiné**, qui dépend directement de la corrélation. Un signal à 0.16 anti-corrélé bat couramment un signal à 0.60 fortement corrélé.

7 Moteur 4 — Momentum Multi-Actifs (15 %)




Fig. 5. Équité et drawdown du Moteur 3 (trois paires EUR-USD, GBP-USD, USD-CAD) pris isolément (non pondéré, non leveragé — avant application des poids 67/9/9/15 et du ciblage de volatilité global). La courbe est relativement plate, mais les pics positifs en 2019, 2023 et début 2026 correspondent exactement aux années faibles des autres moteurs — c'est le profil recherché pour un diversificateur.

Le quatrième moteur est le plus récent et le seul à sortir de l'univers des devises. Il suit la tendance de trois instruments sur données journalières — l'or (XAU-USD), le dollar-yen (USD-JPY) et l'argent (XAG-USD) — avec le même signal appliqué à chacun. Son entrée en production répond à une contrainte précise : sans lui, le mandat de rendement était hors d'atteinte.

Idée clé

Ce moteur a changé trois fois en juillet 2026. Il portait l'or seul à 10 % du capital ; il porte désormais trois instruments équilibrés à 15 %. Les décisions sont distinctes et se justifient différemment : l'élargissement à trois instruments réduit la dépendance à une trajectoire unique (le repli de la sleeve isolée baisse de -76,7 % à -38,0 % en mesure standalone) ; le poids a d'abord été porté à 20 %, puis **ramené à 15 % le 28 juillet** après échec du test de sur-ajustement sur la grille d'allocations (section 13). Le reste de la section décrit le signal, inchangé, puis ce que ces décisions coûtent et rapportent.

7.1 Pourquoi ce moteur, et pourquoi trois instruments

Thèse économique

Le trio FX, combiné et non levierisé, rend 2,2 % par an pour une volatilité de 5,8 %. Le ciblage de volatilité peut amplifier ce résultat, mais pas indéfiniment : au-delà d'un certain levier, le *drag* de variance détruit plus de rendement composé qu'il n'en crée, et le rendement plafonne autour de 32 % avant de retomber. Un mandat à 40 % ne pouvait donc pas être servi par un levier plus élevé — il exigeait une source de rendement supplémentaire, faiblement corrélée aux trois autres.

Le suivi de tendance sur métaux et sur le yen remplit cette condition. Sa corrélation avec chacun des trois moteurs FX est proche de zéro : il ne réagit ni au différentiel de taux qui porte le Momentum Journalier, ni à la micro-structure de session qui porte la Mean Reversion Intraday. À son poids de 15 %, il porte le Sharpe du portefeuille combiné de 0,66 à environ 1,0 (tableau 15), ce qui déplace le plafond de rendement au-dessus de la cible et rend celle-ci atteignable à un niveau de volatilité *inférieur* à celui qu'exigeait le trio seul.

Ce que chaque instrument apporte

Instrument	Ce qu'il apporte	Ce qu'il coûte
Or (XAU-USD)	Le moteur d'origine : la tendance la plus ample de la fenêtre, et 40 % du résultat de la sleeve pour 34 positions.	Un portage <i>négatif</i> — l'or ne rapporte rien à qui le détient, les frais de nuit s'accumulent sur des positions qui durent des semaines.
Dollar-yen (USD-JPY)	Une tendance longue de nature différente (différentiel de taux), et un portage positif : ici les frais de nuit sont une recette, pas une charge.	Une corrélation non nulle avec le Momentum Journalier, qui traite aussi cette paire — les deux moteurs peuvent se retrouver du même côté.
Argent (XAG-USD)	Le poste qui divise le repli : médiocre pris isolément, il casse la dépendance du résultat à la seule trajectoire de l'or. Sur cette fenêtre il apporte la plus grosse part du résultat de la sleeve, 48 % en 20 positions seulement.	L'historique le plus court des trois sur données de courtier propres, et la volatilité la plus élevée.

Le budget de la sleeve est réparti **à parts égales** entre les instruments configurés : chacun reçoit un tiers de la sous-équité, et le dimensionnement d'un instrument ne dépend pas de ce que font les deux autres. Ce choix est délibérément le plus simple possible — une pondération optimisée entre les trois serait une surface d'ajustement supplémentaire pour un gain non démontré.

7.2 Mécanique du signal

Le signal est un *time series momentum* au sens de Moskowitz, Ooi et Pedersen (*Journal of Financial Economics*, 2012) : le rendement passé d'un actif prédit le signe de son rendement futur sur des horizons de un à douze mois. La difficulté pratique de cette famille de signaux n'est pas de la mettre en œuvre, mais de choisir l'horizon sans le sur-ajuster. Ce moteur résout le problème en refusant de choisir.

1. **Quatre horizons, un vote de signe.** À la clôture de chaque séance, et pour chacun des trois instruments séparément, le rendement est mesuré sur 40, 60, 120 et 250 séances. De chacun, on ne retient que le *signe* — pas l'amplitude, nettement plus bruitée. Le signal est la moyenne des quatre signes, donc une valeur dans $\{-1; -0,5; 0; +0,5; +1\}$. La position s'ouvre quand cette moyenne devient strictement positive et se ferme quand elle cesse de l'être.
2. **Aucun horizon n'est optimisé.** Les quatre valeurs sont fixées *a priori* d'après la littérature, jamais ajustées sur l'historique. Moyenner remplace un paramètre choisi par un agrégat, ce qui retire une surface d'ajustement au lieu d'en ajouter une. Un raccourcissement de la grille à (15, 30, 60) a bien été évalué : il paraissait supérieur en simulation Python, et le backtest sur le moteur d'exécution MetaTrader 5 l'a réfuté — 17,3 % de rendement annualisé contre 36,4 % pour la grille d'origine. Les horizons longs ont été conservés.
3. **Long-only.** Il n'y a pas de vente à découvert : quand le vote d'un instrument est négatif, le moteur est hors marché sur cet instrument. Autoriser les positions courtes coûtait 3,8 points de rendement annualisé et doublait le repli maximal (−66,8 % contre −23,3 % sur la fenêtre de recherche).
4. **La séance est bornée à 17h00, heure de New York,** conformément à la convention du courtier sur les CFD. Ce détail n'en est pas un : borner la journée à minuit fabrique 392 fausses séances — les dimanches soir, longs de six heures au lieu de treize — et gonfle le décompte de séances de 20 %, ce qui raccourcit d'autant tous les horizons exprimés en séances. Cette borne fait l'objet d'un verrou de test dédié.
5. **Le moteur est lent.** Le vote de chaque instrument ne bascule qu'une dizaine de fois par an. Sur la fenêtre d'exécution de référence, les trois cumulés représentent 89 positions en cinq ans et quatre mois — 10 % des transactions du portefeuille, contre 4 % du temps où l'or était seul. Les positions se comptent en semaines, et le coût de rotation reste négligeable : environ 0,2 % par an.

7.3 Du signal à la taille de position

Le signal dit *quand* être exposé ; il ne dit pas *combien*. La taille est fixée par une couche de ciblage de volatilité propre au moteur, appliquée avant la couche globale du portefeuille.

$$\text{levier}_t = \min\left(\frac{\sigma^{\text{cible}}}{\hat{\sigma}_t}, L^{\text{max}}\right), \quad \sigma^{\text{cible}} = 0,55, \quad L^{\text{max}} = 6,6$$

où $\hat{\sigma}_t$ est la volatilité annualisée récemment réalisée par l'or. Le mécanisme est contra-cyclique par construction : l'exposition se réduit quand le marché s'agite et augmente quand il se calme. Le plafond L^{max} existe pour le cas inverse — une volatilité réalisée qui s'effondre produirait sinon un levier arbitrairement grand.

Trois précisions sur ces valeurs :

- La cible de 55 % est élevée dans l'absolu, et volontairement. Ce moteur est borné en aval par son allocation de 15 %, elle-même divisée en trois budgets égaux : c'est à ce niveau, et non à l'intérieur du moteur, que son risque est contenu. La formule ci-dessus s'applique instrument par instrument, sur la volatilité propre à chacun.
- Un **stop de sécurité** complète le dispositif : 4 % du prix d'entrée, *ou* quatre écarts-types quotidiens de l'instrument si c'est plus large. Ce n'est pas un stop de stratégie — le signal sort de lui-même — mais un garde-fou contre un décrochage brutal.

Le plancher en écarts-types a été ajouté le 28 juillet 2026, et la raison mérite d'être dite. Une distance fixe de 4 % ne représente pas le même risque selon l'instrument : elle vaut

8,4 écarts-types quotidiens sur le dollar-yen, mais seulement 2,5 sur l'argent, où elle avait cessé d'être un garde-fou pour devenir un stop ordinaire — il coupait **6 sorties sur 23**. Or le moteur de recherche qui valide la stratégie n'a, lui, aucun stop : le comportement mesuré en recherche n'était donc pas celui exécuté sur l'argent. Après correction, ce stop ne déclenche plus que sur 5 % des transactions du moteur. Le dimensionnement des positions, lui, est inchangé — les deux usages de cette distance ont été séparés.

- Le coût modélisé est de **2 points de base par côté**, spread et commission compris. C'est moins que sur les paires FX de la stratégie, ce qui reflète la profondeur des marchés traités ici aux volumes en jeu. Les frais de portage, eux, sont comptés séparément et changent de signe selon l'instrument : charge sur les métaux, recette sur le dollar-yen.

7.4 Dimensionnement progressif : ce qui a été testé, et pourquoi il est écarté

La question posée au départ de ce moteur était explicite : un dimensionnement progressif de type martingale ou grille peut-il améliorer le résultat ? Elle méritait une réponse mesurée plutôt qu'une opinion. Quatre familles de règles ont donc été implémentées, testées et comparées selon un protocole fixé à l'avance.

Les quatre règles, en clair

Règle	Ce qu'elle fait	L'intuition qui la motive
Plate (<i>témoin</i>)	La taille ne dépend pas des résultats passés.	Aucune : c'est la référence contre laquelle les autres doivent démontrer un gain.
Martingale	Après une perte, la taille suivante est multipliée par m (ici 1,5 ou 2), jusqu'à n doublements au plus.	« Une série de pertes finit par s'arrêter ; en misant plus gros au retournement, on récupère le terrain perdu. »
Anti-martingale	L'inverse : on augmente après un gain, on réduit après une perte.	« Les tendances persistent ; il faut charger quand ça marche et se retirer quand ça ne marche pas. »
Grille	Des paliers d'achat supplémentaires sont ajoutés à mesure que le prix évolue <i>contre</i> la position, tous les k écarts-types.	« Moyenner à la baisse abaisse le prix de revient ; le rebond ramène l'ensemble en profit plus vite. »

Ces règles ont une propriété commune qu'il faut énoncer avant tout chiffre : **aucune ne modifie le signal**. Elles ne changent ni le moment d'entrer, ni celui de sortir. Elles ne peuvent donc pas créer de rendement là où le signal n'en produit pas — elles ne font que redistribuer les résultats dans le temps.

Les deux figures suivantes montrent ce que chacune aurait réellement fait sur l'historique du moteur, en appliquant la règle telle qu'elle est codée à la séquence de transactions effectivement produite par le signal de production. L'étude a été conduite sur l'or, instrument d'origine de la sleeve ; sa conclusion porte sur le *mécanisme* de dimensionnement, qui est commun aux trois instruments.

Le protocole de test

Quatre exigences ont été fixées avant de mesurer quoi que ce soit.

1. **Comparer à risque égal**. C'est la précaution décisive. Une martingale prend mécaniquement des positions plus grosses en moyenne : sur la fenêtre de sélection, son exposition

Martingale : la taille double après chaque perte





Fig. 6. Martingale $\times 2$ appliquée aux 47 transactions réelles du moteur or. En haut, la taille exigée sur tout l'historique : elle repart à $1\times$ après chaque gain et double à chaque perte. En bas, le détail de la plus longue série de pertes réellement observée — sept pertes consécutives, à l'issue desquelles la règle réclame $2^7 = 128$ fois la mise initiale pour une huitième position. Le trait orange indique où le plafond de sécurité de $4\times$ coupe l'escalade : à partir de la troisième perte, la martingale ne fait plus ce qu'elle promet.

moyenne atteint 125 % contre 69 % pour le témoin. Comparée telle quelle, elle « gagne » simplement parce qu'elle est plus levierée, ce qui ne démontre rien. Chaque règle a donc été renormalisée à une volatilité réalisée identique de 25 % avant toute comparaison.

2. **Balayer les variantes, pas un réglage.** 24 configurations ont été évaluées : multiplicateurs, nombres de paliers, seuils de déclenchement, et les combinaisons martingale $\times$ grille.
3. **Séparer sélection et validation.** La comparaison a été conduite sur 2019–2025, puis relue sur une fenêtre aveugle de 333 séances (juillet 2025 à juillet 2026) réservée depuis le départ. Cette fenêtre a été choisie parce qu'elle contient à la fois l'envolée de l'or et le repli de -28% qui a suivi : une règle de dimensionnement ne se juge que contre le régime qui la met en difficulté.
4. **Juger sur la queue, pas sur le Sharpe.** Pour chaque règle, la distribution des résultats a été reconstruite par *bootstrap* stationnaire par blocs, d'où sont tirées la probabilité de perdre plus de la moitié du capital, le repli au 95^e centile, l'asymétrie et l'aplatissement de la distribution.

Grille : on rachète par paliers à mesure que le prix descend contre la position

(a) Sur tout l'historique — la grille ajoute au moins un palier sur 20 des 47 positions, et sature à 4× sur 7



(b) Zoom mécanique — position du 19 Oct 2023 au 13 Feb 2024 (84 séances, excursion adverse de 1.8%)




Fig. 7. Grille $k = 0,5$ appliquée aux mêmes positions. En haut, l'exposition maximale atteinte position par position : la grille ajoute au moins un palier sur 20 des 47 positions et sature son plafond de 4× sur sept d'entre elles. En bas, la mécanique sur une position réelle de 84 séances : trois paliers se déclenchent en deux jours lorsque le cours passe sous les seuils dérivés de l'ATR, l'exposition passe de 1× à 4×, et le prix de revient moyen descend de \$1 974 à \$1 953. Ici le cours est ensuite remonté — c'est le cas favorable, celui qui rend la règle séduisante.

Ce que les données disaient avant même le premier backtest

Une martingale suppose qu'une perte rende la perte suivante moins probable — autrement dit, que les résultats successifs soient liés. Cette hypothèse est testable directement sur la séquence des transactions, sans simuler quoi que ce soit.

Test	Résultat	Lecture
Autocorrélation du résultat des transactions (décalage 1)	$\rho = -0,004$, $p = 0,86$	Aucun lien détectable
Gain moyen après une perte <i>vs</i> après un gain	+4,70 contre +0,53 bps, $p = 0,11$	Écart non significatif
Rendement après une excursion adverse de -0,5 à -1 %	-0,44 bps, $t = -4,17$	Moyenner à la baisse a une espérance négative
Rendement lorsque la position est en profit de plus de +0,3 %	+2,48 bps, $t = +24,46$	Renforcer les gains est mieux fondé
Plus longue série de pertes consécutives du moteur livré	7	Une martingale $\times 2$ y aurait exigé $2^7 = 128$ fois la mise initiale

Idée clé

L'avant-dernière ligne est celle qui condamne la grille, et elle mérite d'être lue lentement : sur cet actif, plus le prix s'éloigne contre la position, plus la suite est *défavorable*, pas favorable. Moyenner à la baisse ajoute donc du capital exactement là où l'espérance est la plus mauvaise. La dernière ligne, elle, mesure la distance entre l'idée de martingale et la réalité d'un compte : onze pertes consécutives se sont produites sur la période étudiée.

Résultats sur la fenêtre de sélection (2019–2025)

Toutes les lignes sont ramenées à la même volatilité réalisée. *ann.* est le rendement annualisé, *MAR* le rapport du rendement au repli maximal, et $P(\text{perte} > 50\%)$ la probabilité, estimée par *bootstrap*, de perdre plus de la moitié du capital.

Règle	ann.	Sharpe	repli max	MAR	asymétrie	P(perte > 50 %)
Anti-martingale $m=1,5$	20,25 %	0,81	-46,0 %	0,44	+0,01	0,25 %
Grille $k=2,0$	16,15 %	0,65	-48,1 %	0,34	-0,53	0,30 %
Grille $k=0,5$	15,66 %	0,63	-47,8 %	0,33	-0,53	0,45 %
Plate (témoin)	15,06 %	0,60	-54,3 %	0,28	-0,57	0,60 %
Martingale $m=2$, $n=3$	9,49 %	0,38	-60,0 %	0,16	-0,80	4,70 %
Martingale $\times$ grille	7,34 %	0,29	-63,1 %	0,12	-0,84	8,05 %

Deux observations. La martingale est la plus mauvaise règle de la liste sur cette fenêtre, et sa combinaison avec la grille est pire encore : la probabilité de perdre plus de la moitié du capital passe de 0,60 % pour le témoin à 8,05 %, soit un facteur 13. Et il ne s'agit pas d'un réglage extrême : les résultats sont *identiques* pour $n = 2, 3$ ou 4 paliers, parce qu'avec 43 transactions en six ans et demi les séries de pertes ne dépassent jamais deux. C'est donc le mécanisme dans sa version la plus douce qui sous-performe, ce qui est un constat bien plus solide que si seule la version extrême avait échoué.

La même mesure sur la fenêtre aveugle (2025–2026)

Règle	ann.	Sharpe	repli max	MAR	asymétrie	P(perse > 50 %)
Martingale $m=1,5$, $n=3$	39,0 %	1,56	−18,4 %	2,11	−1,08	0,00 %
Martingale $m=2,0$, $n=3$	38,6 %	1,54	−18,4 %	2,10	−1,08	0,00 %
Plate (témoin)	35,5 %	1,42	−19,1 %	1,86	−1,16	0,00 %
Grille $k=2,0$	35,5 %	1,42	−19,1 %	1,86	−1,16	0,00 %
Anti-martingale $m=1,5$	33,8 %	1,35	−18,6 %	1,81	−1,08	0,00 %
Grille $k=0,5$	33,7 %	1,35	−18,7 %	1,80	−1,08	0,00 %

Le classement s'inverse presque exactement, et c'est le résultat central de toute cette étude :

Règle	Sharpe 2019–2025	rang	Sharpe 2025–2026	rang
Anti-martingale $m=1,5$	0,81	1 ^{er}	1,35	6 ^e
Plate (témoin)	0,60	7 ^e	1,42	4 ^e
Martingale $m=2,0$	0,38	dernier	1,54	2 ^e

Même code, mêmes signaux, deux périodes adjacentes — et une conclusion opposée. La règle classée première devient sixième ; la dernière devient deuxième. Le témoin, lui, reste au milieu du tableau dans les deux cas. La figure 8 donne à voir cette inversion sur les courbes d'équité elles-mêmes.

Mêmes signaux, quatre règles de taille : le classement s'inverse d'une fenêtre à l'autre




Fig. 8. Le même signal passé dans les quatre règles, à volatilité réalisée identique. À gauche la fenêtre de sélection, à droite la fenêtre aveugle. L'anti-martingale (vert) domine la première et se retrouve dernière sur la seconde ; la martingale (rouge) fait exactement l'inverse. Le dimensionnement plat (bleu marine) reste au milieu dans les deux cas. C'est cette instabilité, et non le niveau atteint par l'une ou l'autre, qui a décidé du choix retenu.

Thèse économique

Une hiérarchie qui s'inverse entre deux fenêtres voisines ne mesure pas une propriété de la règle ; elle mesure la séquence de transactions que chaque période contenait. C'est la définition même d'un résultat non reproductible. La fenêtre aveugle contenait par hasard exactement la séquence pour laquelle une martingale est construite — des pertes pendant la baisse, puis un rebond capté avec une position agrandie. La fenêtre de sélection ne la contenait pas.

Pourquoi la fenêtre favorable ne peut pas servir d'argument

Il serait tentant de retenir la martingale sur la foi de la seconde fenêtre. Deux raisons l'interdisent.

D'abord, cette fenêtre est **aveugle au risque qui décide**. Sur les 24 configurations testées, elle rapporte $P(\text{perte} > 50\%) = 0,00\%$ pour toutes sans exception, une probabilité de ruine nulle partout, et un écart de repli maximal de 0,7 point entre la meilleure et la pire. Elle classe donc les règles sur le seul rendement, sur une période sans véritable épisode de stress. Adopter la martingale sur cette base reviendrait à la choisir précisément sur l'axe que cette période ne peut pas mesurer.

Ensuite, ce qui est stable d'une fenêtre à l'autre n'est pas le classement : c'est la **forme de la distribution**.

	2019–2025	2025–2026
Repli au 95 ^e centile — martingale	62,8 %	45,3 %
Repli au 95 ^e centile — <i>plate</i>	54,8 %	32,2 %
$P(\text{perte} > 50\%)$ — martingale	1,40 %	0,20 %
$P(\text{perte} > 50\%)$ — <i>plate</i>	0,10 %	0,00 %
Asymétrie / aplatissement — martingale	–1,15 / 19,4	–0,57 / 6,7
Asymétrie / aplatissement — <i>plate</i>	–0,66 / 10,6	–0,69 / 8,2

Dans chaque fenêtre sans exception, la martingale porte une queue de pertes nettement plus lourde pour un rendement qui n'est pas fiablement supérieur. Y compris sur la fenêtre qui lui est favorable, où sa probabilité de perte majeure reste le double de celle du témoin.

Avertissement

Ce que cela signifie concrètement pour un compte réel. Une martingale ne déplace pas l'espérance de gain : elle échange « beaucoup de petits gains » contre « une perte rare et lourde ». La moyenne bouge peu, la queue gauche s'allonge. La conséquence pratique est qu'un Sharpe élevé mesuré sur un historique de martingale n'est pas une preuve de qualité — c'est un tirage dans une distribution très dispersée. **Une martingale peut afficher un excellent résultat jusqu'à la transaction qui l'anéantit.** C'est exactement ce que la seconde fenêtre montre, et c'est pourquoi elle n'a pas été retenue comme argument.

Conclusion retenue

Thèse économique

Le moteur est livré en dimensionnement plat. Les trois raisons, par ordre de poids :

1. **Aucune règle progressive n'est stable.** Le classement s'inverse entre deux fenêtres adjacentes ; ce qu'elles mesurent ne persiste pas.
2. **La seule fenêtre qui les favorise est aveugle au risque qui les disqualifie.** Elle ne distingue aucune des 24 règles sur la probabilité de perte majeure ni sur le repli.
3. **Le dimensionnement plat n'offre aucune prise à l'ajustement.** Pas de multiplicateur, pas de nombre de paliers, pas de seuil : il ne peut pas être sur-ajusté, et il se classe au milieu du tableau dans les deux fenêtres plutôt que premier dans l'une et dernier dans l'autre.

Le dossier de l'anti-martingale était réel et méritait d'être instruit : c'était la seule règle à corriger la forme de la distribution sur la fenêtre de sélection, avec une asymétrie ramenée à +0,01 contre -0,57 pour le témoin. Elle n'a simplement pas survécu au contact d'une seconde période. Les quatre règles restent implémentées et couvertes par des tests unitaires dans le code livré, mais elles sont désactivées.

Avertissement

Une réserve de méthode, énoncée pour ce qu'elle vaut. La fenêtre aveugle a été relue une seconde fois pour arbitrer cette question, après qu'une correction de la définition des séances eut modifié le classement de sélection. Elle est donc « dépensée » : une troisième lecture reviendrait à sélectionner sur la période de validation. Toute proposition ultérieure de dimensionnement progressif exigera une tranche de données réellement nouvelle, et non celle-ci.

7.5 Performance historique

7.6 Épisodes représentatifs

Tab. 8. *Épisodes représentatifs du sleeve Gold Momentum sur XAU-USD. Les épisodes longs correspondent aux tendances de l'or captées par le croisement de moyennes ; leur amplitude explique que la sleeve porte l'essentiel du résultat malgré 10 % du poids.*

Entrée	Sortie	Sens	Durée	Rendement
2020-02-17	2020-02-21	Long	5 j	14.79 %
2006-04-06	2006-04-19	Long	9 j	13.09 %
2019-03-28	2019-03-29	Long	2 j	0.65 %
2020-02-25	2020-02-28	Short	4 j	-16.06 %
2026-01-29	2026-01-30	Short	2 j	-18.25 %




Fig. 9. Équité et drawdown du Moteur 4 pris isolément (non pondéré, non leveragé). La ligne verticale pointillée marque le début de la fenêtre hors échantillon.

7.7 Ce que ce moteur doit à sa période

Avertissement

2019–2026 a été un marché haussier des métaux d’une ampleur inhabituelle, doublé d’une mégatendance sur le yen. Le prix de l’or a plus que doublé sur la fenêtre. Un moteur de suivi de tendance y réalise mécaniquement sa meilleure performance possible, et rien dans les données disponibles ne permet de distinguer la part qui revient au signal de celle qui revient au régime. Élargir la sleeve à trois instruments ne corrige pas ce biais : les trois ont tendu dans le même sens sur la même période.

Trois constats l’illustrent. D’abord, le Sharpe du portefeuille croît de façon monotone avec le poids accordé à cette sleeve sur toute la plage testée : l’optimum était à la borne de la grille (20 %), signature d’un biais de période et non d’un optimum démontré. **Le test de sur-ajustement l’a confirmé** (section 13) : le poids le mieux classé sur une moitié des données retombe sous la médiane sur l’autre dans près de deux découpages sur trois. Le poids a donc été ramené à **15 %** le 28 juillet 2026. Ensuite, même à ce poids réduit, la sleeve porte une part du budget de risque très supérieure à sa part de capital. Enfin, à l’exécution, ce moteur produit 87,0 % du résultat net du portefeuille pour 10 % de ses transactions.

Le taux de gain de la sleeve est de 39,8 % : elle perd trois fois sur cinq. C’est une amélioration réelle par rapport aux 31,4 % de l’or seul — trois instruments produisent trois séquences de tendance moins synchrones — mais sa rentabilité tient toujours à l’amplitude de quelques positions gagnantes, comportement attendu d’un suivi de tendance, et son résultat futur reste dépendant de la persistance des tendances.

Deux réserves héritées du dossier de recherche complètent ce tableau. L'argent est le **maillon le plus court** : son historique de données de courtier propres est le plus récent des trois, et sa contribution mesurée repose donc sur moins d'observations que celle de l'or. Et l'ensemble des chiffres d'exécution de ce document sont des **majorants** : le simulateur reconstruit les prix à partir des bougies OHLC à la minute, ce qui donne au moteur un remplissage légèrement plus favorable que la réalité tick par tick.

8 Recherche et exécution : deux mesures, un seul compte

Ce portefeuille est mesuré par deux moteurs différents, et il est essentiel de comprendre pourquoi leurs chiffres ne se superposent pas. La recherche est conduite sous **vectorbtpro**, qui permet d'explorer rapidement des milliers de configurations. L'exécution est assurée par un *Expert Advisor* MetaTrader 5, qui passe les ordres réels. Les deux ont été rapprochés ligne à ligne sur les signaux — ils déclenchent aux mêmes barres — mais ils ne dimensionnent pas les positions de la même manière.

8.1 Le mot «levier» ne désigne pas la même quantité

Recherche (vbt)	Le levier multiplie directement le poids de position . Un levier de 12 signifie que le portefeuille est exposé à douze fois son capital sur la série de rendements considérée.
Exécution (MT5)	Le levier multiplie un budget de risque borné par la distance au stop . Le notionnel ouvert vaut le pourcentage de capital risqué divisé par l'écart entre le prix d'entrée et le stop — un nombre volontairement petit, que le levier vient ensuite amplifier.

La conséquence est qu'à réglage nominal identique, les deux moteurs n'ouvrent pas la même taille. Le moteur de recherche atteint la volatilité qu'il vise ; le moteur d'exécution, dont le levier est plafonné par le rapport entre volatilité cible et plancher de volatilité, ne peut pas générer assez de notionnel pour l'atteindre. L'écart n'est pas un défaut de portage : c'est une différence de définition, qu'aucun réglage de sleeve ne peut résorber.

Idée clé

Sous ciblage de volatilité, aucun paramètre de dimensionnement d'une sleeve ne déplace la volatilité du portefeuille. Diviser par six l'exposition d'un moteur fait mécaniquement monter le levier global d'autant, et les métriques agrégées ne bougent pas. Seuls les budgets de risque de base et le plafond de levier comptent. Ce résultat, contre-intuitif, a coûté une journée d'investigation avant d'être établi.

8.2 Comment l'échelle a été calibrée

Plutôt que de réconcilier deux définitions incompatibles, un facteur d'échelle unique (**Inp_RiskScale**) a été introduit côté exécution : il met à l'échelle les budgets de risque des quatre sleeves d'un même coefficient. Sa valeur a été mesurée dans le testeur, pas déduite d'une formule.

Le rendement répond quasi linéairement à ce facteur, tandis que le nombre de transactions ne bouge pas d'une unité : le paramètre dimensionne les positions sans toucher aux signaux. Le Sharpe s'érode lentement à mesure que la taille augmente, les coûts de transaction pesant plus lourd.

Avertissement

Ce réglage multiplie le risque réellement pris dans la proportion exacte où il multiplie le rendement. Il a été fixé sous instruction explicite du mandant, le risque ayant été déclaré non contraignant. À échelle unitaire, le même portefeuille produirait un rendement environ quatre fois inférieur, pour un repli réduit dans la même proportion.

8.3 Ce qu'il faut en retenir pour lire ce document

1. **Les chiffres de performance publiés sont ceux de MetaTrader 5** (section 1). Ils incluent le *spread* du courtier, l'arrondi des lots et les frais de portage.
2. **Les chiffres de recherche servent à éprouver la structure**, pas à annoncer un rendement. Les sections 10 à 13 les emploient pour répondre à une question différente : la stratégie tient-elle sur des trajectoires que l'histoire n'a pas produites ?
3. **Les deux ne sont pas transposables l'un à l'autre.** Un rendement annualisé issu de la recherche ne préjuge pas de ce que le compte produirait, et ce document ne l'utilise jamais à cette fin.

9 Architecture de pondération et gestion du risque

9.1 Allocation statique 67 / 9 / 9 / 15

L'allocation du portefeuille est **statique et non discrétionnaire** :

Moteur	Poids cible
Moteur 1 — Mean Reversion Intraday Filtré	67 %
Moteur 2 — Momentum Journalier Multi-Paires	9 %
Moteur 3 — Mean Reversion Journalière par RSI	9 %
Moteur 4 — Momentum Multi-Actifs (or, dollar-yen, argent)	15 %

Cette grille a été révisée en juillet 2026 : la sleeve momentum est passée de 10 à 20 %, puis a été ramenée à 15 % le 28 juillet après échec du test de sur-ajustement sur la grille d'allocations (section 13). Les cinq points nets sont pris sur la seule Mean Reversion Intraday ; les poids du Momentum Journalier et du RSI Journalier sont inchangés depuis l'origine. L'annexe C mesure ce que d'autres répartitions auraient donné.

Idée clé

Un cinquième moteur est présent dans le programme, à poids nul. Le fichier livré compile une sleeve *H1 Momentum* — un suivi de tendance sur données horaires — dont l'allocation `Inp_AllocH1Momentum` vaut 0. Ce n'est ni un oubli ni une réserve : le moteur a été construit, intégré et mesuré en isolation dans le simulateur d'exécution, où il

rend un Sharpe de $-3,98$. Le critère d'abandon — « Sharpe autonome inférieur à $0,5 \rightarrow$ on n'intègre pas » — avait été écrit *avant* de lancer la mesure ; il a été appliqué tel quel. Le code est conservé compilé plutôt que supprimé, pour qu'une refonte ultérieure reparte d'une base déjà branchée sur la couche de risque. **Laisser ce paramètre à zéro** : le porter au-dessus activerait un moteur dont la seule mesure disponible est franchement négative.

Pas d'adaptation de régime, pas de risk-parity dynamique. Ce choix, contre-intuitif à première vue, est le résultat de plusieurs tests comparatifs conduits pendant la recherche :

- Une allocation dite *regime-adaptive*, fondée sur une matrice de priors indexée par régime de volatilité et de tendance, a été testée et *sous-performe* une allocation par risk-parity simple (Sharpe 0.51 contre 0.64). La raison : les régimes ne sont pas suffisamment différenciés sur la fenêtre historique disponible pour que la commutation de poids apporte un gain net.
- Une allocation par risk-parity (inverse-vol) concentre mécaniquement les poids sur le Moteur 1 dont la volatilité intrinsèque est très basse, sans bénéfice marginal puisque sa volatilité n'est pas le facteur limitant de sa contribution.
- Les poids statiques offrent l'avantage supplémentaire d'un **turnover quasi-nul** au niveau portefeuille : les frais de rebalancement inter-moteurs sont estimés à $5-10$ points de base par an, négligeables face au rendement visé par le mandat.

9.2 Couche de ciblage de volatilité

Le ciblage de volatilité est appliqué globalement sur le portefeuille combiné. À chaque instant t , le levier est calculé selon :

$$\text{lev}_t = \min \left(\frac{v^*}{\max(\sigma_{t-1}^{21}, \sigma_{t-1}^{63})_{\text{clip} \geq 0.02}}, L_{\max} \right)$$

avec $v^* = 0.37$ la volatilité cible, $L_{\max} = 31$ le plafond de levier, et σ^{21} et σ^{63} les volatilités réalisées annualisées sur 21 et 63 jours glissants respectivement.

Quatre points de conception méritent explication :

1. **Estimateur pessimiste** $\max(\sigma^{21}, \sigma^{63})$: prendre le maximum entre une fenêtre courte (réactive aux chocs) et une fenêtre longue (stable) protège contre la sur-leverage en période de calme apparent. Pendant les transitions de régime, la volatilité courte monte avant la longue, et l'estimateur capture immédiatement le nouveau régime.
2. **Lag d'un bar anti look-ahead** : le levier à l'instant t utilise les volatilités calculées strictement avant t — aucune information future ne contamine le calcul.
3. **Plancher de volatilité à 0.02** : empêche un levier infini pendant les périodes ultra-calmes (phase pré-crise typique), où la volatilité réalisée peut s'effondrer sous 1 % annualisé.
4. **Plafond dur à $31\times$** : il borne l'exposition que le calcul réclamerait pendant les périodes de volatilité réalisée très basse. Le plafond agit comme une soupape de sécurité pré-événement, qui limite l'exposition maximale même en période de calme prolongé.

Idée clé

Sensibilité aux paramètres du ciblage de volatilité : le tableau 9 balaie la volatilité cible de 0.20 à 0.50 et le plafond de levier de 20 à 45 . Le Sharpe y est *constant* sur presque toute la grille, ce qui appelle une lecture précise : le ciblage de volatilité déplace

le portefeuille le long d’une même droite rendement–risque. Choisir une cible plus élevée n’améliore pas la qualité de la stratégie, cela achète plus de rendement au prix exactement proportionnel en volatilité et en repli. Le choix (0.37, 31) n’est donc pas un optimum de Sharpe — c’est le point de cette droite qui sert le rendement visé.

Tab. 9. Sensibilité du Sharpe à (*target_vol*, *max_leverage*). Le point de production (0.37, 31×) y rend un Sharpe de 0.985, contre 0.995 au meilleur point de la grille (0.50, 20×).

Config	ml=20	ml=31	ml=45
tv=0.20	0.985	0.985	0.985
tv=0.28	0.985	0.985	0.985
tv=0.33	0.985	0.985	0.985
tv=0.37	0.985	0.985	0.985
tv=0.42	0.989	0.985	0.985
tv=0.50	0.995	0.985	0.985




Fig. 10. Trajectoire du levier effectif appliqué par la couche de ciblage de volatilité. La ligne pointillée orange matérialise le plafond dur à 31×, la ligne pointillée bleue la moyenne empirique sur la période complète. Le levier s’abaisse mécaniquement pendant les épisodes de volatilité réalisée élevée (début 2020, mi-2022, début 2023) puis revient au plafond dès que la volatilité redescend. La ligne verticale pointillée marque le début de la fenêtre hors échantillon.

9.3 Impact du levier sur les métriques

Un point de pédagogie financière souvent mal compris par les lecteurs non techniques mérite d’être explicité avant la présentation des résultats. Le ciblage de volatilité n’est *pas* un mécanisme qui crée du rendement : c’est un mécanisme qui *aligne* la volatilité réalisée du portefeuille sur la cible du mandat. Sous un scaling par un facteur *constant* *k*, le CAGR, la volatilité et le Max Drawdown sont tous multipliés par *k* et le Sharpe Ratio reste strictement invariant. En pratique notre overlay applique un scaling *variable* (contraint par le plafond 31× et la volatilité réalisée glissante), ce qui produit un léger écart Sharpe entre les deux lignes du tableau

ci-dessous — attribué à l'interaction entre l'overlay et la structure temporelle des rendements, pas à une source d'alpha nouvelle.

Tab. 10. *Impact du ciblage de volatilité sur les métriques du portefeuille. Le Sharpe est structurellement invariant sous un scaling de levier par un facteur constant ; l'overlay ne crée donc pas de valeur ex nihilo, il ajuste l'exposition à la volatilité cible du mandat. La ligne non leveragée constitue la vraie métrique d'edge statistique ; la ligne leveragée reflète l'expression opérationnelle de cet edge aux contraintes de volatilité du client. Le multiplicateur effectif moyen (rapport des volatilités réalisées) est inférieur au plafond $31\times$ car le levier s'abaisse pendant les périodes de volatilité élevée.*

Configuration	CAGR	Vol ann.	Sharpe	Max DD
Pondéré 67/9/9/15 sans levier	2.23 %	3.92 %	0.57	-10.12 %
Pondéré 67/9/9/15 avec ciblage vol 0.37 / cap $31\times$	35.95 %	37.27 %	0.96	-50.37 %
Multiplicateur effectif moyen	$9.5\times$ (rapport volatilité leveragée / non leveragée)			

Idée clé

Comment lire le tableau 10 : la ligne non leveragée représente la qualité statistique réelle du signal combiné, à l'allocation de production. Elle est modeste sur l'axe du rendement car les quatre moteurs tournent à leur volatilité intrinsèque naturelle, particulièrement basse pour un MR-intraday filtré. La ligne leveragée applique ensuite l'overlay de volatilité qui porte le portefeuille à l'exposition du mandat. Le Sharpe des deux lignes reste du même ordre de grandeur : l'edge statistique mesuré est celui de la première ligne ; le levier est un outil d'expression opérationnelle, pas une source de performance *ex nihilo*. Le repli de la ligne leveragée est celui de la ligne non leveragée multiplié par le levier moyen effectif — c'est ce facteur, et lui seul, qui sépare un repli de quelques points d'un repli de plusieurs dizaines de points.

9.4 Protection drawdown — disponible, désactivée, et non remplacée

Le moteur de backtest dispose également d'un mécanisme de *drawdown cap* qui déleverage progressivement le portefeuille à mesure que le drawdown s'approfondit, selon une table pré-calibrée :

Drawdown courant	Échelle de levier appliquée
0–10 %	$1.00\times$ (inchangé)
10–20 %	taper linéaire $1.00 \rightarrow 0.60$
20–30 %	taper $0.60 \rightarrow 0.35$
30–35 %	taper $0.35 \rightarrow 0.15$ (plancher)

Le drawdown est calculé sur l'équité pré-cap et lagué d'un bar pour éviter toute circularité.

Avertissement

Pourquoi ce dispositif est-il désactivé dans la configuration retenue ? Deux raisons se sont succédées. La première est empirique : les tests ont mesuré que le *drawdown cap* dégradait le Sharpe au lieu de le protéger, parce qu'il déleverage pendant la phase de rebond et prive le portefeuille du retour à la moyenne qui aurait restauré l'équité. La

seconde tient au mandat actuel : le plafond de repli qu'il servait à défendre a été retiré, si bien que le dispositif n'a plus de seuil à faire respecter.

Il n'existe donc aujourd'hui aucun coupe-circuit automatique sur ce portefeuille. Le repli d'équité mesuré à l'exécution atteint 47,0 % ; rien dans la configuration ne l'aurait interrompu s'il était allé plus loin. C'est un choix assumé, pas un oubli, mais il doit être connu de quiconque déploie la stratégie.

Le dispositif reste disponible dans le moteur et peut être réactivé sans modification de code, avec le seuil de repli que le mandant jugerait acceptable.

10 Performance de recherche in-sample

Avertissement

Cette section mesure le moteur de recherche, pas le compte. Les chiffres qui suivent proviennent du backtest `vectorbtpro` ; ils servent à éprouver la structure de la stratégie sur des trajectoires alternatives, pas à annoncer une performance. Les chiffres de performance publiés sont ceux de l'exécution MetaTrader 5 (section 1). Les deux ne sont pas transposables l'un à l'autre — la section 8 explique pourquoi.

10.1 Métriques agrégées

Tab. 11. Métriques clés du portefeuille sur les trois régimes d'évaluation. Les colonnes *Bootstrap* rapportent moyenne et percentiles P5/P95 d'un block bootstrap stationnaire sur la période in-sample. Chiffres issus d'un **backtest** `vectorbtpro` : voir la section dédiée pour les résultats de l'exécution MetaTrader 5, qui font foi pour le compte réel.

Métrique	In-sample	Out-of-sample	Bootstrap moyenne	Bootstrap P5 / P95
CAGR	21.92 %	194.45 %	34.34 %	6.39 % / 65.42 %
Volatilité ann.	37.38 %	36.22 %	38.07 %	34.88 % / 41.55 %
Max Drawdown	-50.37 %	-17.09 %	-52.62 %	-73.00 % / -35.72 %
Sharpe Ratio	0.72	3.17	0.92	0.36 / 1.47
Années / runs positifs	6/7	—	98.4 %	—

Avertissement

La colonne « Out-of-sample » de ce tableau annualise une fenêtre de 449 barres. Son CAGR de 181.48 % n'est ni une performance ni une prévision : il extrapole à l'année un segment de quelques mois qui recouvre la phase la plus favorable du marché des métaux. Le chiffre est reporté pour la transparence du calcul et ne figure dans aucune conclusion de ce document. La section 11 le détaille.

Tab. 12. Performance standalone (non pondérée) des 4 sleeves sur la période complète 2000–2026. Les chiffres sont non-leveragés et non-allocés ; le poids indiqué entre parenthèses est celui que la sleeve reçoit dans le portefeuille.

Sleeve	Rendement total	CAGR	Vol ann.	Sharpe	Max DD
MR Macro (67 %)	14.0 %	0.51 %	3.79 %	0.13	-16.66 %
TS Momentum 3p (9 %)	35.7 %	1.19 %	3.26 %	0.36	-11.76 %
RSI Daily 3p (9 %)	53.8 %	1.68 %	16.30 %	0.10	-51.80 %
Gold Momentum (15 %)	727.5 %	8.50 %	17.78 %	0.48	-40.47 %

- **CAGR** : 23.08 %
- **Volatilité annualisée** : 37.00 %
- **Max Drawdown** : -55.00 %
- **Sharpe Ratio** : 0.75
- **Fenêtre** : du 1^{er} avril 2019 au 1^{er} avril 2025

Idée clé

Un repli de 55 % sur la mesure de recherche. Ce n'est pas une anomalie de calcul : c'est ce que produit mécaniquement une cible de volatilité de 37 % appliquée à un portefeuille dont la volatilité naturelle est de quelques points. Le moteur de recherche atteint cette cible ; le moteur d'exécution, dont le dimensionnement passe par un budget de risque borné par le stop, n'y parvient pas et réalise un repli plus faible. L'écart entre les deux chiffres est une différence de définition, pas une contradiction.

10.2 Validation par fenêtres annuelles (walk-forward)




Fig. 11. Sharpe annuel du portefeuille combiné sur la période historique, tel que mesuré par le moteur de recherche. Le détail année par année figure au tableau 13.

Tab. 13. *Sharpe walk-forward par année sur la fenêtre glissante. 6 années sur 7 sont positives ; année(s) négative(s) : 2023.*

Année	Sharpe WF	Statut
2019	1.34	positive
2020	0.49	positive
2021	0.49	positive
2022	2.24	positive
2023	-0.06	négative
2024	1.95	positive
2025–2026-04	3.54	positive

- **2019** (+1.22) : le régime de fin de cycle, longtemps présenté comme défavorable à la stratégie, lui est en réalité favorable sous la configuration actuelle.
- **2020** (+0.88) : année du choc Covid, positive malgré tout. Le filtre macro bloque le Moteur 1 pendant l'essentiel de la période, le privant du rebond.
- **2021** (+0.45) : la fenêtre la plus terne des positives.
- **2022** (+2.31) : le cycle de hausses de la Fed et la parité EUR-USD alimentent le suivi de tendance.
- **2023** (−0.20) : seule fenêtre négative de la série. C'est aussi la seule année négative du compte à l'exécution.
- **2024** (+2.21) : seconde meilleure fenêtre, les quatre moteurs alignés.
- **2025 à avril 2026** (+3.45) : dernière fenêtre, plus longue que les autres. Elle recouvre en partie la tranche de données gelée par la politique de *holdout* — elle est rapportée ici à titre de mesure, elle n'a servi à aucun choix de paramètre.

Avertissement

Ces Sharpe de fenêtre ne sont pas des rendements annuels. Ils mesurent la régularité du signal à l'intérieur de chaque fenêtre, pas ce que le compte aurait gagné. Le résultat année par année du compte figure au tableau 3, et il raconte une histoire voisine : une seule année négative, 2023, et une concentration du gain sur 2024–2026.

10.3 Heatmap des rendements mensuels

10.4 Courbe *underwater* du drawdown

10.5 Sharpe glissant sur 63 jours

10.6 Corrélations glissantes entre moteurs

10.7 Contribution mensuelle par moteur

11 Validation hors échantillon

La validation hors échantillon est le test le plus important de tout travail de recherche quantitative : c'est la seule manière de distinguer un *edge* structurel d'un artefact d'ajustement. Le portefeuille y obtient un Sharpe supérieur à celui de la période de conception — résultat favorable, mais dont cette section explique aussi les limites.




Fig. 12. Rendements mensuels du portefeuille combiné. Les mois verts dominent la distribution ; les mois rouges restent généralement contenus à quelques points de pourcentage.




Fig. 13. Courbe de drawdown du portefeuille combiné. Le drawdown maximal atteint -55.00% sur la fenêtre in-sample de recherche.

11.1 Comparaison directe

Métrique	In-sample	Hors échantillon	Interprétation
Nombre de barres	6995	449	OOS $\approx 6\%$ de l'IS
Rendement total cumulé	372.2 %	193.3 %	Fenêtre courte, effet de composition
CAGR	23.08 %	181.48 %	Annualisation d'une fenêtre de 449 barres
Volatilité	37.00 %	36.59 %	Comparable
Max Drawdown	-55.00 %	-17.84 %	DD beaucoup plus contenu
Sharpe Ratio	0.75	3.02	OOS supérieur à l'IS




Fig. 14. Sharpe Ratio calculé sur une fenêtre glissante de 63 jours (environ un trimestre). La ligne pointillée orange représente le seuil de 1.0. Le Sharpe est positif deux tiers du temps (66 % des fenêtres) et culmine à 7.4 en mai 2024, mais chaque année de l'historique contient à la fois des pics au-dessus de 2.5 et des passages sous zéro : la régularité s'apprécie sur l'année, pas sur le trimestre.

Avertissement

Le CAGR hors échantillon de 181 % ne doit être lu ni comme une performance, ni comme une prévision. C'est l'annualisation d'une fenêtre de 449 barres qui recouvre précisément la phase la plus favorable du marché des métaux. Étendre un rendement de quelques mois à une base annuelle amplifie mécaniquement tout ce que cette période contenait de circonstanciel. Le chiffre est rapporté pour la transparence du calcul ; il ne figure dans aucune conclusion de ce document.

Idée clé

Lecture critique : un véritable surajustement aurait typiquement produit une dégradation sévère hors période de conception — un Sharpe qui passe de > 1 à proche de zéro ou même négatif. Ici le Sharpe hors échantillon est *supérieur* à l'in-sample, et le repli maximal nettement plus faible. Cela réfute l'hypothèse d'un surajustement *majeur*, sans pour autant établir que la performance se reproduira : les tests de la section 13 nuancent ce constat, et l'un d'eux échoue.

11.2 Zoom sur la fenêtre de validation

11.3 Caveat méthodologique sur le caractère OOS

Avertissement

La fenêtre hors échantillon est un découpage *ex-post* — elle a été isolée après coup, lorsque ces données sont devenues disponibles. Il ne s'agit donc pas d'un *holdout* pré-engagé avant le design, et elle recouvre en partie la tranche que la politique de *holdout* du projet a gelée




Fig. 15. Corrélation glissante à 63 jours pour les six paires de moteurs, moyenne de période en légende. En haut, les paires internes au trio FX : Momentum Journalier × RSI Journalier reste majoritairement négative (-0,24 en moyenne), ce qui est le levier de diversification identifié sur la pleine période. En bas, les trois paires impliquant la sleeve momentum : les moyennes sont faibles (-0,00, +0,18, -0,08), ce qui fonde la contribution de ce moteur à la diversification. **La moyenne masque toutefois des épisodes marqués** : la corrélation entre la sleeve momentum et le Momentum Journalier atteint +0,65 sur plusieurs séquences de quelques mois — les deux moteurs traitent d'ailleurs le même dollar-yen depuis juillet 2026 — deux moteurs de suivi de tendance s'alignent naturellement lorsque les régimes sont directionnels. La décorrélation est une propriété de long terme, pas une garantie instantanée : sur ces épisodes, les deux moteurs perdent ou gagnent ensemble.

pour la sélection de modèle. Elle est ici utilisée pour *rapporter*, jamais pour choisir un paramètre.

Trois éléments soutiennent néanmoins le résultat :

1. Le Sharpe hors échantillon est *supérieur* à l'in-sample, pas simplement *proche* — c'est l'opposé d'une dégradation par surajustement.
2. Le repli maximal hors échantillon est bien plus faible qu'en in-sample, ce qui n'est pas non plus cohérent avec un surajustement.
3. Les hyperparamètres de chaque moteur sont restés inchangés lors des évolutions successives de l'allocation.

Action corrective retenue : un *paper-trade* d'un minimum de trois mois avant tout déploiement de capital réel, pour consolider la validation par une fenêtre authentiquement pré-engagée.




Fig. 16. Contribution mensuelle pondérée (67 / 9 / 9 / 15) de chaque moteur au rendement du portefeuille combiné. Le Moteur 1 domine la contribution positive la majorité du temps, avec des compléments décisifs du Moteur 3 lors des années difficiles pour le Moteur 1.




Fig. 17. Zoom sur la période hors échantillon (courbe orange), base 100 à la date de coupure. La courbe in-sample est conservée en arrière-plan pour référence.

12 Tests de résistance — bootstrap historique

12.1 Méthodologie

On applique un *bootstrap* par blocs mobiles sur la série de rendements du portefeuille combiné. La méthode consiste à ré-échantillonner des blocs consécutifs d'environ un mois, ce qui préserve les autocorrélations intra-mois (volatility clustering, mean reversion) tout en décorrélant la séquence macroéconomique. Le ré-échantillonnage produit un millier de trajectoires alternatives qui respectent la structure locale des rendements mais explorent les ordres temporels plausibles.

12.2 Résultats

Tab. 14. Résultats du block bootstrap stationnaire sur la période in-sample : moyenne et percentiles P5/P50/P95 de chaque métrique. La ligne « Cible atteinte » donne la fraction des tirages dont le CAGR tombe dans la bande visée.

Métrique	Moyenne	P5	P50	P95
CAGR	34.34 %	6.39 %	33.16 %	65.42 %
Max DD	-52.62 %	-73.00 %	-51.23 %	-35.72 %
Sharpe	0.92	0.36	—	1.47
Pos. fraction		98.4 %		
Cible atteinte		18.7 %		

12.3 Interprétations critiques

Idée clé

Trois observations fondamentales :

1. **Le repli médian des trajectoires est de -49.23 %, et son 5^e percentile de -70.83 %.** Autrement dit, une trajectoire sur vingt subirait un repli de plus des deux tiers du capital. C'est le profil de risque qu'implique la cible de volatilité retenue, mesuré sans plafond de drawdown pour l'interrompre.
2. **99.1 % des trajectoires sont positives** (CAGR strictement supérieur à zéro). L'*edge* lui-même est robuste à l'ordre temporel de l'historique : c'est son *amplitude*, pas son signe, que le dimensionnement met en jeu.
3. **Fraction « cible atteinte » : 20.0 %** des trajectoires tombent dans la bande de CAGR visée. La dispersion est large — du 5^e au 95^e percentile, le CAGR va de 9.24 % à 67.49 %. Atteindre la cible sur une trajectoire donnée relève donc pour une part du tirage.

12.4 Stabilité face aux hyperparamètres de ciblage de volatilité

Le même rapport de stress conduit une analyse de sensibilité sur le couple (volatilité cible, levier maximal). Le tableau reproduit en section 9 montre un Sharpe pratiquement constant sur toute la grille. Cela ne signifie pas que le choix est indifférent : le ciblage de volatilité déplace le portefeuille le long d'une même droite rendement-risque, si bien qu'un réglage plus ambitieux achète du rendement au prix exactement proportionnel en repli. La robustesse porte sur la *qualité* du signal, pas sur le niveau de risque, qui reste un choix.




Fig. 18. Nuage de points bootstrap CAGR × Max Drawdown. Chaque point coloré est une trajectoire ré-échantillonnée. Les étoiles marquent les réalisations in-sample (bleu marine) et hors échantillon (orange). Les lignes pointillées horizontales délimitent la bande de CAGR visée par le mandat, [35 %, 45 %]. Aucune ligne de drawdown n'est tracée : le mandat n'en fixe plus.

Avertissement

Limite inhérente du bootstrap : le ré-échantillonnage préserve la structure autocorrélée locale mais *n'injecte pas* de chocs sévères au-delà de ce que l'historique disponible contient déjà. Il réordonne le passé, il n'invente pas de crise. En particulier, il ne teste pas un régime durablement défavorable aux tendances des métaux et du yen, alors que ce moteur porte 87,0 % du résultat. Il ne teste donc pas la robustesse à un scénario de type « crise financière 2008 » ou « choc pétrolier 1979 ». Pour compléter, la section suivante présente un rejeu explicite de scénarios historiques sélectionnés.

13 Robustesse statistique avancée

13.1 Pourquoi un Sharpe ponctuel ne suffit pas

Un Sharpe rapporté seul est une *statistique ponctuelle* dont la fiabilité dépend de trois biais bien documentés en recherche quantitative : le bruit d'estimation sur échantillon fini, le biais de sélection lorsqu'on rapporte la meilleure configuration parmi plusieurs testées, et la dépendance temporelle des rendements qui viole l'hypothèse d'indépendance sous-jacente aux tests classiques. Cette section applique une batterie de tests statistiques qui répondent à chacun de

ces biais et produisent des intervalles de confiance, des corrections pour tests multiples et des mesures de sur-ajustement. Le verdict consolidé est donné en fin de section : **quatre des six tests franchissent leur seuil ; les deux qui échouent portent sur ce que la sélection a coûté, pas sur l'existence de l'edge**. Les formules et la procédure de chaque test sont détaillées en annexe D.

13.2 Intervalles de confiance bootstrap sur les métriques

Le bootstrap par blocs stationnaires ré-échantillonne la série de rendements en préservant l'autocorrélation locale (volatility clustering, mean reversion de court terme) tout en décorrélatant la structure macroéconomique à l'échelle mensuelle. Chaque ré-échantillon donne un vecteur de métriques ; les quantiles à 2.5 % et 97.5 % forment l'intervalle de confiance à 95 %.

Exemple concret

Le bootstrap par blocs sur 10 rendements — illustration jouet. Imaginons une série réelle de 10 rendements journaliers observés :

$$r = (\underbrace{+1.2, -0.8, +0.3}_{\text{calme}}, \underbrace{-2.1, +1.9, -1.7, +2.3}_{\text{volatile}}, \underbrace{+0.5, -0.4, +0.6}_{\text{calme}}) \%$$

Un bootstrap *classique* (Efron 1979) tire 10 valeurs avec remise de façon indépendante. Résultat probable : on mélange à égale chance les jours calmes et les jours volatils, *détruisant* la structure temporelle — le ré-échantillon ressemble à une série iid alors que l'original ne l'est pas.

Le *block bootstrap stationnaire* tire au contraire des **blocs contigus** de longueur géométrique moyenne $L = 3$. Un ré-échantillon typique pourrait être :

$$r^* = (\underbrace{r_4, r_5, r_6}_{\text{bloc } L=3}, \underbrace{r_8, r_9}_{\text{bloc } L=2}, \underbrace{r_2, r_3, r_4, r_5}_{\text{bloc } L=4}, r_1)$$

Le deuxième bloc $(r_4, r_5, r_6) = (-2.1, +1.9, -1.7)$ est **copié intact** : les trois jours volatils restent consécutifs, donc le *volatility clustering* local est préservé. En répétant l'opération 3 000 fois, on obtient une distribution bootstrap du Sharpe dont la variance reflète la vraie incertitude statistique, au lieu d'être artificiellement réduite par l'hypothèse iid.

Tab. 15. Intervalles de confiance bootstrap à 95 % sur 13 métriques standard (*Omega Ratio omis, mathématiquement identique à Profit Factor au niveau rendement*). Métriques de risque affichées selon la convention usuelle (*drawdown négatif, volatilité positive*). La ligne Rendement total couvre la période complète du backtest et ne se compare pas directement à la colonne IS du Tableau 11.

Métrique	Observée	Moy. bootstrap	Médiane (P50)	CI 2.5 %	CI 97.5 %
Rendement total	+1157.75 %	+2303.62 %	+1201.27 %	+47.14 %	+10917.53 %
Sharpe Ratio	0.985	1.000	1.002	0.311	1.677
Calmar Ratio	0.687	0.807	0.719	0.071	2.013
Sortino Ratio	1.434	1.479	1.466	0.427	2.615
Rendement annualisé	+34.62 %	+36.34 %	+35.16 %	+4.64 %	+73.70 %
Max Drawdown	-50.37 %	-50.59 %	-49.50 %	-75.68 %	-31.92 %
Profit Factor	1.225	1.231	1.229	1.067	1.405
VaR 5%	-3.31 %	-3.32 %	-3.29 %	-3.75 %	-2.78 %
Tail Ratio	1.130	1.123	1.121	0.966	1.311
Volatilité annualisée	+37.27 %	+37.16 %	+37.16 %	+33.81 %	+40.48 %
Information Ratio	0.062	0.063	0.063	0.020	0.106
Downside Risk	+25.60 %	+25.47 %	+25.43 %	+22.46 %	+28.67 %
CVaR 5%	-5.64 %	-5.61 %	-5.60 %	-6.35 %	-4.94 %




Fig. 19. Forest plot des cinq métriques principales. Le diamant orange marque la valeur observée, la barre bleue l'intervalle de confiance bootstrap à 95 %. La borne basse du Sharpe (0.308) est strictement positive, ce qui est la condition statistique minimale pour qu'une stratégie soit considérée comme ayant un edge non-nul avec un niveau de confiance de 95 %.

Idée clé

L'intervalle de confiance à 95 % du Sharpe est [0.308, 1.712]. Le fait que la borne basse soit strictement positive — et non seulement la moyenne — est la condition statistique minimale pour qu'une stratégie soit considérée comme ayant un *edge* distinguable




Fig. 20. Distribution bootstrap du Sharpe ratio. La ligne orange matérialise la valeur observée (0.999), les deux lignes vertes pointillées matérialisent les bornes de l'intervalle de confiance à 95 % [0.308, 1.712]. La distribution est légèrement asymétrique à droite, cohérente avec les queues épaisses des rendements FX.

du bruit avec un niveau de confiance de 95 %. Même dans le scénario pessimiste au 2.5^e percentile, le Sharpe reste à 0.308.

Deux zones de vigilance identifiées.

- L'intervalle de confiance du **Max Drawdown** s'étend de -76.47% à -32.25% , pour une réalisation observée de -55.00% . Il n'existe plus de plafond contractuel auquel comparer ces valeurs : elles décrivent le risque encouru, elles ne signalent pas un dépassement.
- L'intervalle de confiance du **Tail Ratio** est [0.973, 1.452] pour une réalisation observée de 1.120. La borne basse est passée sous 1 avec la montée en poids de la sleeve momentum : la domination des gains extrêmes sur les pertes extrêmes reste le cas central, elle n'est plus acquise sur toute la distribution.

13.3 Equity fan chart — trajectoires bootstrap alternatives

Le *fan chart* condense les trajectoires d'équité bootstrap alternatives en bandes de percentiles : P₅/P₉₅ en bande claire, P₂₅/P₇₅ en bande plus foncée, P₅₀ en médiane et la courbe observée superposée en bourgogne.

La bande P₅ reste plate voire négative sur les premières années, ce qui reproduit la réalité observée — la seule fenêtre walk-forward négative est 2023 (section 10). Le bootstrap capture donc la variance résiduelle des années les plus difficiles de l'historique.

13.4 Tests d'overfitting

Cinq tests complémentaires sont appliqués. Chacun pose une question légèrement différente. **Trois franchissent leur seuil, deux échouent** : la probabilité de sur-ajustement et la longueur minimale de *backtest*. Ces deux échecs sont discutés en détail plus bas et repris dans le verdict consolidé ; le premier a directement conduit à réduire le poids de la sleeve momentum.




Fig. 21. Fan chart bootstrap — trajectoires alternatives compressées en bandes de percentiles. La courbe observée (bourgogne) reste dans la partie supérieure du fan à partir de 2023. Sur la fenêtre hors échantillon, la courbe observée sort du fan P25–P75 vers le haut : le Sharpe hors échantillon dépasse la médiane bootstrap, ce qui est cohérent avec une stratégie qui n'est pas un pur artefact de l'échantillon d'entraînement.

Tab. 16. Tests de correction d'overfitting. 3 test(s) sur 5 franchissent leur seuil sur le portefeuille combiné ; les autres échouent et sont signalés dans la colonne d'interprétation. Références : Bailey & López de Prado (2012, 2014, 2015), Harvey & Liu (2015).

Test	Valeur	Interprétation
PSR vs 0	1.0000	$P(\text{Sharpe vrai} > 0)$ élevé — présence d'edge
DSR ($N = 382$ trials)	1.0000	Seuil $E[\max \text{SR}] = 0.185$
Haircut Sharpe (BHY)	0.947	Ratio survivant = 96.11 %
MinBTL (années)	12.25	Pour Sharpe cible 0.99
PBO CSCV ($n_{\text{bins}} = 16$)	0.649	Seuil de danger = 0.5 (<i>OVERFIT</i>)

- **Probabilistic Sharpe Ratio (PSR)** = 1.000 : la probabilité que le vrai Sharpe soit supérieur à zéro est de 100 %, après correction pour la non-normalité des rendements.
- **Deflated Sharpe Ratio (DSR)** = 1.000 : après correction pour le biais de sélection sur les 382 configurations distinctes du registre d'essais, le Sharpe observé dépasse d'un facteur 5 l'espérance du maximum sous hypothèse nulle (0.99 contre 0.185). Le portefeuille combiné n'est pas le fruit d'un *best of N*.

Avertissement

Ce que ce DSR ne couvre pas, et qui est mesuré ailleurs. Le $N = 382$ est désormais celui du registre d'essais du projet et non, comme dans les éditions antérieures de ce rapport, le nombre de *sleeves* ($N = 6$) — une déclaration qui répondait à « ce

portefeuille est-il le meilleur de six ? » plutôt qu'à « est-il le meilleur de tout ce qui a été essayé ? ».

Mais la déflation ne dit rien du *choix des instruments*. Déflaté par la dispersion des 21 instruments classés au criblage, le Sharpe de chacun des trois retenus tombe très en-dessous du seuil : $\mathbb{E}[\max \text{SR}] = 2,89$ contre 0,74 pour l'or, 0,51 pour le dollar-yen et 0,20 pour l'argent. **Ce qui résiste à la correction, c'est l'assemblage ; ce qui n'y résiste pas, c'est la sélection des instruments qui le composent.** Le criblage désigne des candidats, il ne les démontre pas.

Exemple concret

Pourquoi le DSR est-il plus sévère que le PSR — l'analogie du concours de pile ou face. Supposons qu'on organise un concours où $N = 1\,000$ participants lancent chacun une pièce équilibrée 100 fois et reportent leur taux de « face ». Par chance pure, *au moins un* participant va tomber sur un score spectaculaire — disons 65 faces sur 100, soit un z -score de +3. Cela ne prouve **rien** sur son habileté : c'est l'espérance mécanique du maximum sur 1 000 essais.

Le **PSR** répond à : *ce participant-là est-il statistiquement différent de 50 % ?* Il regarde uniquement ses 100 tirages. Il dira oui.

Le **DSR** répond à : *ce participant est-il significatif sachant qu'il est le vainqueur de 1 000 essais ?* Il compare son $z = 3$ à $\mathbb{E}[\max z] \approx \sqrt{2 \ln 1000} \approx 3.72$. Conclusion : non, son score est en-dessous de ce qu'on attend par chance. Le DSR dira non.

Application Apogée. Avec $N = 382$ configurations distinctes déclarées au registre d'essais, $\mathbb{E}[\max \text{SR} \mid N = 382] = 0.185$. Le Sharpe observé $\widehat{\text{SR}} = 0.99$ dépasse ce seuil d'un facteur 5, d'où $\text{DSR} \approx 1.000$. Le seuil croît en $\sqrt{2 \ln N}$, donc lentement : passer de 382 à 10 000 essais ne le porterait qu'à 0.240. **Ce qui fait vraiment bouger la déflation, ce n'est pas N , c'est la dispersion des essais rivaux** — ici $\hat{\sigma}(\text{SR}) = 0.062$ entre des allocations quasi identiques, donc un seuil bas.

Et c'est précisément la limite de ce test ici. Les 382 essais sont des variantes du *même* portefeuille ; leur faible dispersion rend le seuil facile à franchir, et le verdict favorable est en partie mécanique. Appliquée à une famille réellement hétérogène — les 21 instruments du criblage, dont les Sharpe s'étalent de -1.05 à $+0.78$ — la même formule donne un seuil de 2.89 que *aucun* candidat ne franchit. Le PBO, lui, ne dépend d'aucun N déclaré : c'est pourquoi son verdict est le plus informatif des cinq, et c'est lui qui a tranché ici.

- **Haircut Sharpe** = 0.947 (ratio de survie 96.11 %) : après correction pour tests multiples, le Sharpe effectif reste à 0.947. On perd 4 % du Sharpe à la correction, ce qui est faible.
- **Minimum Backtest Length** = 12.25 ans — **échec** : sous 382 essais déclarés, il faudrait 12.25 années d'historique pour qu'un Sharpe de 0.99 soit distinguable du hasard. On en dispose de 8.5. L'écart n'est pas réhibitoire mais il est réel, et il ne se comble que par du temps.
- **Probability of Backtest Overfitting (PBO)** = 0.649 — **échec** : dans 64.9 % des découpages temporels, l'allocation la mieux classée sur la moitié in-sample retombe sous la médiane out-of-sample. Le seuil de danger est 0.5. **Ce test est mesuré sur la grille d'allocations réellement parcourue** — les onze combinaisons de composition et de poids du

criblage — et non, comme dans les éditions antérieures, sur la matrice des quatre *sleeves*, qui répondait à une question jamais posée dans ce projet.

Exemple concret

Le Haircut Sharpe étape par étape. On part du Sharpe observé $\widehat{SR} = 0.99$ sur $T = 2\,146$ barres journalières, avec $N = 382$ essais.

1. *Aller en t-stat* : $t_{\text{obs}} = 0.99 \times \sqrt{2145} \approx 45.6$ — statistiquement énorme sous hypothèse nulle.
2. *P-value brute* (survie Student-t) : p_{raw} est de l'ordre de 10^{-6} ou moins.
3. *Correction BHY* pour $N = 382$ essais : on multiplie par N puis par le 382^e nombre harmonique $c(382) \approx \ln 382 + 0.577 \approx 6.52$. Le facteur de pénalité total est donc $\approx 2\,490$.
4. *Retour en t-stat* : $t_{\text{adj}} = \Phi_{\text{Student}}^{-1}(1 - p_{\text{adj}}) \approx 43.9$.
5. *Retour en Sharpe* : $SR_{\text{haircut}} = 43.9 / \sqrt{2145} \approx 0.947$, soit un ratio de survie de $0.947 / 0.99 = 96\%$.

Intuition. Le BHY pénalise le Sharpe de façon d'autant plus douce que l'*edge* initial est grand par rapport à sa variance d'estimation. Une stratégie avec $\widehat{SR} = 0.25$ et les mêmes paramètres verrait son Haircut s'effondrer à quasi-zéro : la correction « mord » d'autant plus fort que le signal est faible.

Exemple concret

Le PBO démystifié — CSCV avec $S = 4$ blocs. Le CSCV réel utilise $S = 16$ blocs et $\binom{16}{8} = 12\,870$ partitions, difficile à visualiser. Réduisons à $S = 4$ blocs et $\binom{4}{2} = 6$ partitions pour voir le mécanisme.

On découpe les 7 ans de rendements en 4 blocs temporels B_1, B_2, B_3, B_4 de taille égale. Pour chaque partition, on choisit 2 blocs pour l'in-sample et les 2 autres pour l'out-of-sample :

Partition	In-sample	Out-of-sample	Logit
1	B_1, B_2	B_3, B_4	+1.4
2	B_1, B_3	B_2, B_4	+0.8
3	B_1, B_4	B_2, B_3	+0.3
4	B_2, B_3	B_1, B_4	-0.2
5	B_2, B_4	B_1, B_3	+1.1
6	B_3, B_4	B_1, B_2	+0.5

Pour chaque partition, on identifie le *vainqueur* in-sample — la configuration au meilleur Sharpe sur B_1, B_2 par exemple — puis on regarde son rang out-of-sample sur B_3, B_4 . Ce rang est converti en *logit* : positif si le vainqueur reste dans la moitié supérieure, négatif s'il tombe sous la médiane.

Dans ce jouet à 6 partitions, **1 sur 6** a un logit négatif (partition 4). Le PBO vaudrait donc $1/6 \approx 0.17$: sous 0.5, régime sain. **Le vrai CSCV est nettement plus sévère que ce jouet.** Sur les 12 870 partitions réelles, Apogée reporte PBO = 0.649 — environ 8 350 partitions sur 12 870 voient un retournement IS→OOS, soit deux sur trois. Le seuil critique est franchi et le test échoue.

D'où vient cet échec. Il n'a rien de mystérieux : quand trois positions portent 82 % du résultat (section 15), l'allocation qui les surpondère domine mécaniquement toute partition qui les contient, et se classe mal dans celles qui ne les contiennent pas. Le PBO mesure exactement cette instabilité. C'est la raison pour laquelle le poids de la sleeve momentum a été ramené de 20 % à 15 %.




Fig. 22. Distribution des logits de validation croisée combinatoire. La ligne verticale orange matérialise le seuil au-dessus duquel le vainqueur in-sample est au-dessus de la médiane out-of-sample (en-dessous : overfitting manifeste). Le PBO de 0.649 signifie que 64.9 % de la masse de la distribution est à gauche du seuil — une majorité, d'où l'échec du test.

Idée clé

L'edge passe, la sélection échoue — et les deux verdicts sont compatibles. PSR et DSR à 1.000 indiquent que le Sharpe observé est très loin de ce qui s'obtiendrait par chance pure, et le *Haircut* ne prélève que 4 % du Sharpe. Mais le PBO échoue à 0.649, et la longueur minimale de *backtest* requise (12.25 ans) dépasse l'historique disponible (8.5 ans).

Les tests répondent à des questions différentes : le PSR et le DSR demandent « l'edge est-il réel ? », le PBO demande « le choix qu'on a fait parmi les candidats se transporte-t-il hors échantillon ? ». **La réponse est oui à la première et non à la seconde.** Un moteur peut avoir un avantage authentique et avoir été *dosé* sur du bruit : c'est exactement le diagnostic ici, et il porte sur le poids, pas sur l'existence du signal. La correction appliquée est du même ordre — réduire le poids, ne pas retirer le moteur.

13.5 Tests de supériorité prédictive

Avec la matrice des rendements des onze allocations candidates du criblage contre un *benchmark* à rendement nul, on teste si *au moins une* d'entre elles bat statistiquement le *benchmark* après correction de *data snooping*. Deux tests complémentaires sont appliqués : le test de supériorité prédictive (Hansen SPA) et la procédure stepwise de Romano–Wolf.

Tab. 17. Tests de supériorité prédictive avec correction de data snooping sur les composantes individuelles. Hansen SPA (2005) renvoie une p-value globale ; Romano–Wolf StepM (2005) contrôle le FWER en renvoyant l'ensemble des stratégies dominantes.

Test	Résultat
Hansen SPA — p-value bas	0.5730
Hansen SPA — p-value cohérent	0.5730
Hansen SPA — p-value haut	0.9990
Romano–Wolf StepM ($\alpha = 0.05$)	0/11 composantes




Fig. 23. P-values du test de supériorité prédictive sur les onze allocations candidates. Les trois bornes correspondent à trois estimateurs différents du re-centering, la borne cohérente étant celle recommandée en pratique. La ligne pointillée orange matérialise le seuil $\alpha = 0.05$.

Avertissement

Les p-values élevées ici ne contredisent pas le DSR à 1.000. Les deux tests répondent à des questions différentes : le DSR teste la *configuration retenue* contre un seuil tenant compte du nombre d'essais, tandis que ces tests demandent si une allocation candidate se détache significativement des dix autres. Elles sont quasi identiques par construction — même moteur, poids voisins — donc aucune ne domine, et le StepM ne retient 0 candidat sur 11. C'est le résultat attendu, et il rejoint le diagnostic du PBO : **le classement des allocations entre elles n'est pas une information solide**. C'est leur *combinaison* (pondération fixe 67/9/9/15 et ciblage de volatilité global) qui produit le profil mesuré ici, pas la supériorité démontrable d'un point de la grille sur ses voisins.

13.6 Stabilité temporelle multi-métrique

Une stratégie robuste doit avoir ses métriques de risque ajusté qui restent positives et relativement stables, sans décrochages prolongés. On trace donc le Sharpe, le Sortino et le Calmar ratios glissants sur une fenêtre d'un an de trading.




Fig. 24. Stabilité temporelle des trois métriques de risque ajusté. Les trois courbes restent majoritairement positives sur 2019–2026, avec un creux en 2023 — la seule année négative de la série walk-forward — et des pics en 2022 et 2024. La ligne pointillée verticale marque le début de la fenêtre hors échantillon.

13.7 Verdict consolidé

Tab. 18. Verdict consolidé sur les tests de robustesse statistique : 4 test(s) sur 6 franchissent leur seuil. La dernière ligne est reportée sans verdict : le plafond de drawdown ayant été retiré de la configuration de production, elle ne répond plus à une contrainte.

Test	Seuil	Résultat	Verdict
Intervalle de confiance 95 % Sharpe	Borne basse > 0	[0.311, 1.677]	PASSÉ
Probabilité Sharpe vrai > 0	> 0.95	1.0000	PASSÉ
Sharpe corrigé pour biais de sélection	> 0.95	1.0000	PASSÉ
Ratio de survie après tests multiples	> 50 %	96.11 %	PASSÉ
Longueur backtest > minimum statistique	< longueur observée	12.25 ans > 8.5 ans	ÉCHEC
Probabilité de sur-ajustement	< 0.5	0.649	ÉCHEC
Bootstrap — pire drawdown à 95 %	aucun plafond actif	-75.68 %	mesure

Thèse économique

Quatre tests sur six franchissent leur seuil. Les deux échecs ne portent pas sur l’existence de l’edge, mais sur ce que la *sélection* a coûté : la probabilité de sur-ajustement vaut 0.649 pour un seuil de 0.5, et la longueur minimale de *backtest* requise sous 382 essais (12.25 ans) dépasse l’historique disponible (8.5 ans). 382 configurations distinctes ont été évaluées sur la même fenêtre, chaque phase héritant des meilleurs points de la précédente, et le poids de la sleeve momentum avait été arrêté à la borne du domaine testé (section 7). **Ce poids a été ramené de 20 % à 15 % à la suite de ce test**, selon une règle de décision écrite et horodatée avant le calcul. C’est

aussi la raison pour laquelle une tranche de données a été gelée, et pour laquelle le *paper-trade* préalable de la section 16 n'est pas une formalité : c'est la seule validation de ce portefeuille qui soit authentiquement pré-engagée.

14 Rejeu de scénarios historiques

Le rejeu de scénarios complète le bootstrap en testant la stratégie sur des fenêtres historiques réelles et identifiables : crises, régimes de hausse de taux, années de rallye. Contrairement au bootstrap qui produit des séquences synthétiques, le rejeu préserve la séquence macroéconomique originale et permet de vérifier le comportement de la stratégie dans des contextes précisément nommés.

Tab. 19. *Rejeu de scénarios historiques, chacun mesuré sur sa propre fenêtre. 3 des 6 épisodes ressortent avec un Sharpe négatif; le plus favorable est « 2024 complet » (1.45), le plus défavorable « 2020 Q1 Covid » (-2.21).*

Scénario	N bars	Rend. total	CAGR	Max DD	Sharpe
2019 complet	365	44.67 %	43.03 %	-24.20 %	1.19
2020 Q1 Covid	71	-19.98 %	-66.76 %	-30.01 %	-2.21
2020 complet	366	-2.29 %	-2.21 %	-36.07 %	0.13
2022 Q3 crise GBP	122	-5.99 %	-16.22 %	-15.14 %	-0.46
2023 hausses de taux	365	-13.69 %	-13.34 %	-20.30 %	-0.27
2024 complet	366	59.92 %	57.08 %	-16.93 %	1.45

14.1 Lecture détaillée des six scénarios

- **2019 année complète (Sharpe +1.11, repli -26.23 %)** : la seconde meilleure fenêtre de la série, contrairement à ce que laissaient penser les configurations antérieures du portefeuille. L'entrée de la sleeve momentum et le relèvement de la cible de volatilité ont transformé une année autrefois négative en l'une des plus rentables du lot.
- **2020 Q1 Covid (Sharpe -2.14, repli -26.71 %)** : la pire fenêtre. Le choc frappe simultanément les quatre moteurs, et le dimensionnement actuel amplifie la perte dans la même proportion qu'il amplifie les gains. C'est le scénario qui illustre le plus directement le coût du niveau de risque retenu.
- **2020 année complète (Sharpe +0.44, repli -32.70 %)** : la récupération post-Covid ramène l'année en territoire positif, mais au prix d'un repli intermédiaire de près d'un tiers du capital — sans plafond de drawdown pour l'interrompre.
- **2022 Q3 crise GBP (Sharpe -0.34, repli -14.20 %)** : la crise du *mini-budget* britannique se solde par une perte. Les versions antérieures de ce document présentaient cette fenêtre comme l'une des meilleures de l'historique ; ce n'est plus vrai sous la configuration actuelle.
- **2023 année de hausses (Sharpe -0.43, repli -22.46 %)** : l'année négative de la série, sur les deux moteurs de mesure — c'est aussi la seule année négative du compte à l'exécution et la seule fenêtre walk-forward négative.

- **2024 année complète (Sharpe +1.66, repli -15.21 %) :** la meilleure fenêtre. Les quatre moteurs sont alignés.

14.2 Observations transversales

Idée clé

Ce que ces six fenêtres établissent :

- **La moitié des épisodes est négative.** Trois Sharpe sur six sont sous zéro. Le portefeuille n'est pas robuste *à tous* les régimes : il est rentable en moyenne parce que ses bonnes fenêtres sont plus amples que ses mauvaises.
- **Les épisodes de stress ne sont pas absorbés, ils sont subis.** Covid 2020 et la crise GBP 2022 produisent tous deux des pertes. Aucun mécanisme de la stratégie ne réduit l'exposition à l'entrée d'un régime défavorable — le ciblage de volatilité réagit à la volatilité réalisée, avec le retard que cela implique.
- **Le repli intermédiaire est systématiquement supérieur au résultat final.** Même 2020, positive au bout du compte, traverse un repli de près d'un tiers du capital. Un investisseur qui juge sur la trajectoire, et non sur le solde de fin d'année, aurait vécu une expérience très différente de celle que résume le rendement annuel.

Avertissement

Biais de sélection des scénarios. La liste ci-dessus inclut délibérément à la fois de bonnes et de mauvaises années, mais elle n'épuise pas tous les régimes possibles. Les crises non testées incluent :

- Crise *subprime* 2007–2008 (absence de données minute FX de qualité pour cette période).
- Choc pétrolier 1979–1980 (structurellement différent, non comparable au régime actuel).
- Sortie brutale d'un *peg* monétaire (par exemple le CHF de janvier 2015) — extension envisageable à la demande.
- **Un marché baissier durable des métaux, ou une inversion durable de la tendance du yen.** C'est l'omission la plus importante : la période disponible ne contient aucun régime prolongé défavorable au moteur qui porte 87,0 % du résultat, et les trois instruments de ce moteur ont tendu dans le même sens sur toute la fenêtre.

Le bootstrap par blocs mobiles agit comme compensation partielle à cette limite, mais il réordonne le passé et n'invente pas de régime absent.

15 Analyse des risques et limites méthodologiques

Un audit méthodologique a été conduit avant la présentation de ce rapport. **Six avertissements** sont identifiés et divulgués ci-dessous. Aucune erreur structurelle n'a été détectée dans la chaîne de calcul — pas de biais de *look-ahead*, pas de bug numérique, bootstrap méthodologiquement correct — mais deux des avertissements ci-dessous portent sur la nature même de la performance, et non sur sa mesure.

Thèse économique

Les tests de robustesse ne sont pas tous franchis, et le rapport le dit. La section 13 documente le *block bootstrap* stationnaire sur les 14 métriques (intervalle de confiance 95 % du Sharpe strictement positif), le *Probabilistic Sharpe Ratio*, le *Deflated Sharpe Ratio*, le *Haircut Sharpe* de Benjamini–Hochberg–Yekutieli, le *Minimum Backtest Length*, ainsi que les tests de supériorité prédictive Hansen SPA et Romano–Wolf StepM. La *Probability of Backtest Overfitting* mesurée par validation croisée combinatoire vaut 0,649 pour un seuil de danger de 0,5 : **ce test échoue**. Il porte sur la grille d’allocations réellement parcourue pour fixer le poids de la sleeve momentum, et sa conséquence a été appliquée — ce poids est ramené de 20 % à 15 % selon une règle de décision écrite avant le calcul. Les avertissements ci-dessous sont les limites qui subsistent après cette correction.

15.1 Avertissement 1 — Le résultat repose sur un seul moteur, et davantage qu’avant

Avertissement

Nature du risque : à l’exécution, la sleeve momentum produit 87,0 % du résultat net du portefeuille pour 10 % de ses transactions et 15 % de son allocation. Les trois moteurs FX, qui portent 85 % de l’allocation et 816 des 905 transactions, ne contribuent ensemble qu’à 13,0 % du gain.

Et à l’intérieur de cette sleeve, le résultat tient à quelques positions. Une position unique sur l’argent, ouverte le 21 mai 2025 et fermée le 19 mars 2026, apporte 46,6 % du résultat net du portefeuille. Les trois plus grosses positions — sur 905 transactions — en apportent 80 %. Ce n’est pas une propriété du suivi de tendance en général ; c’est la propriété de *cette* fenêtre, où deux mouvements exceptionnels ont été captés par des positions tenues plusieurs mois.

Concentration temporelle : 64,3 % du résultat net a été acquis dans les quatre mois de janvier à avril 2026, une tranche que la recherche s’était interdite pour toute sélection de modèle. Les cinq années sur lesquelles les paramètres ont été choisis (2021–2025) apportent le tiers restant. Le rendement affiché décrit donc majoritairement une période qui n’a pas servi à construire la stratégie — ce qui est méthodologiquement sain, mais rend le chiffre de tête peu représentatif du régime de croisière.

Impact potentiel : le portefeuille est présenté comme diversifié sur quatre sources d’alpha, mais son *résultat* ne l’est pas. Un régime durablement défavorable au suivi de tendance ne serait pas compensé par les trois autres moteurs à leur niveau de contribution actuel. La diversification a servi à rendre la cible de rendement atteignable, elle n’a pas réparti le risque de résultat.

Aggravant : 2019–2026 a été un marché haussier des métaux d’ampleur inhabituelle, doublé d’une méгатendance sur le yen.

Aggravant secondaire : l’argent est l’instrument dont l’historique de données de courtier propres est le plus court, et il *perd* 2 440 \$ sur les cinq années de la fenêtre de sélection : la totalité de son apport provient de la tranche gelée de 2026. Sa contribution est donc mesurée sur beaucoup moins d’observations utiles que celle de l’or.

Action corrective : le poids de la sleeve a été ramené de 20 % à 15 % le 28 juillet 2026 à la suite du test d’*overfitting* décrit à l’avertissement 2. Suivre la contribution par sleeve et par instrument en production, et alerter si la concentration se maintient au-delà de deux

trimestres. Réexaminer le poids sur une tranche de données réellement fraîche, postérieure à juillet 2026.

15.2 Avertissement 2 — La sélection a consommé du pouvoir statistique

Avertissement

Nature du risque : la *Probability of Backtest Overfitting*, mesurée sur la grille d'allocations qui a produit la recommandation, vaut 0,649 contre un seuil de danger de 0,5. **Ce test échoue.** La procédure estime que l'allocation la mieux classée sur une moitié des données se retrouve sous la médiane sur l'autre moitié dans près de deux découpes sur trois.

Ce chiffre corrige une mesure antérieure. Les éditions précédentes de ce rapport annonçaient 0,335 et un verdict favorable : cette valeur portait sur la matrice des quatre *sleeves*, et répondait donc à la question « choisir le meilleur moteur tient-il hors échantillon », qui n'est pas une décision prise dans ce projet. Le nombre publié ici porte sur la grille réellement parcourue pour fixer le poids de la *sleeve momentum*. Pour la même raison, le *Deflated Sharpe* est désormais déflaté par les 382 configurations distinctes du registre d'essais, contre 6 auparavant — ce dernier chiffre étant le nombre de *sleeves*, non le nombre d'essais.

Origine : 382 configurations distinctes ont été évaluées au fil de la recherche sur la même fenêtre historique, chaque phase héritant des meilleurs points de la précédente. Le mécanisme précis de l'échec est lisible dans l'avertissement 1 : quand trois positions portent 82 % du résultat, l'allocation qui les surpondère domine les découpes qui les contiennent et se classe mal dans les autres.

Ordre de grandeur à retenir : la longueur minimale de historique requise pour qu'un Sharpe de 0,99 soit distinguable du hasard sous ce nombre d'essais est de 12,25 années. La fenêtre de recherche sur laquelle ce Sharpe est mesuré en couvre 8,5 — et le *backtest* d'exécution MetaTrader 5, plus courte, 5,3.

Action corrective appliquée : le poids de la *sleeve momentum* a été ramené de 20 % à 15 %, conformément à une règle de décision écrite et horodatée *avant* le calcul du test. Une tranche de données reste gelée et retirée de la sélection de modèle. Le *paper-trade* préalable de la section 16 n'est pas une formalité : c'est la seule validation authentiquement pré-engagée dont ce portefeuille dispose.

15.3 Avertissement 3 — Aucun coupe-circuit n'est actif

Avertissement

Nature du risque : le mécanisme de plafonnement du drawdown existe dans le moteur mais il est désactivé, et le mandat ne fixe plus de limite de repli. Le repli d'équité mesuré à l'exécution atteint 47,0 % ; le bootstrap situe le 5^e percentile du repli à environ -71 %.

Impact potentiel : il n'existe aucun mécanisme automatique pour interrompre une perte en cours. Le ciblage de volatilité réduit l'exposition *après* que la volatilité réalisée a augmenté, avec le retard que cela implique ; ce n'est pas un dispositif de protection du capital.

Action corrective : dimensionner la réserve de capital sur le repli constaté et non sur un plafond contractuel qui n'existe plus. Le plafonnement de drawdown peut être réactivé sans modification de code, au seuil que le mandant jugerait acceptable.

15.4 Avertissement 4 — Le dimensionnement multiplie le risque autant que le rendement

Avertissement

Nature du risque : le facteur d'échelle appliqué aux budgets de risque à l'exécution a été calibré pour atteindre la cible de rendement. Le rendement y répond quasi linéairement — et le repli aussi, dans la même proportion.

Impact potentiel : à échelle unitaire, le même portefeuille produirait un rendement environ quatre fois inférieur pour un repli réduit d'autant. Le niveau retenu est un choix de risque, pas une propriété de la stratégie.

Action corrective : ce paramètre est un point de réglage unique et documenté. Il peut être abaissé à tout moment sans toucher aux signaux : le nombre de transactions reste identique.

15.5 Avertissement 5 — Coûts de transaction au niveau portefeuille

Avertissement

Nature du risque : le calcul du rendement combiné en recherche applique une somme pondérée des moteurs et ne charge pas explicitement les coûts de rebalancement inter-moteurs. Les coûts intra-moteur (*slippage* et frais) sont en revanche chargés par chaque pipeline individuel, et le backtest MetaTrader 5 intègre le *spread* réel du courtier.

Impact sur la stratégie : l'écart est de quelques points de base par an sur la mesure de recherche. Il est sans effet sur les chiffres publiés, qui proviennent du moteur d'exécution.

Action corrective : monitoring du *slippage* réel en live et comparaison systématique aux hypothèses du backtest.

15.6 Avertissement 6 — Hyperparamètres des sub-stratégies

Avertissement

Nature du risque : les valeurs par défaut des indicateurs (bandes de Bollinger, seuil de *spread* macro, EMA 20/50, périodes RSI) sont issues d'analyses préparatoires conduites sur une période partiellement chevauchante avec la fenêtre in-sample. La documentation formelle d'un découpage entraînement/test pour ces choix individuels est partielle.

Mitigation partielle : ces paramètres sont stables sur les grilles de sensibilité — les *heatmaps* de Sharpe montrent un plateau, pas un pic isolé.

Action corrective : revalidation périodique des grilles de chaque sub-stratégie. Si le plateau reste stable, la robustesse est confirmée.

15.7 Tableau récapitulatif des risques

#	Risque	Gravité	Mitigation
1	Résultat concentré sur une sleeve	Élevée	Suivi de contribution, réexamen du poids sur données fraîches
2	Pouvoir statistique consommé	Moyenne	Tranche de données gelée, <i>paper-trade</i> pré-engagé
3	Aucun coupe-circuit actif	Élevée	Réserve dimensionnée sur le repli réel, plafond réactivable
4	Dimensionnement agressif	Élevée (choisie)	Paramètre unique, abaissable sans toucher aux signaux
5	Coûts de rebalancement non chargés	Faible	Monitoring live du <i>slippage</i>
6	Surajustement hyperparamètres	Faible	Revalidation périodique des grilles

16 Conditions de déploiement

Avant tout déploiement avec capital réel, chaque élément ci-dessous doit être validé. L'ordre est important : certains éléments bloquent les suivants. Cette check-list constitue la stratégie de risque opérationnelle du mandat.

- Paper-trade d'au moins trois mois** sur la configuration présentée, avec un broker identique à la cible de production. **Critère de passage** : Sharpe live supérieur ou égal à 1.0 sur la fenêtre paper.
- Réserve de marge d'au moins 30 %** en cash hors-broker, accessible en moins de 24 heures. Cette réserve absorbe les *tails* au-delà du 5^e percentile bootstrap.
- Alerte automatique de drawdown live** : arrêt automatique du trading si le drawdown depuis le *high water mark* dépasse 15 %. Le seuil à 15 % est choisi pour déclencher l'alerte *avant* d'atteindre la bande la plus favorable du bootstrap (−34.93 % au 95^e percentile du repli), en laissant une marge de décision manuelle.
- Monitoring par moteur, et par instrument sur le Moteur 4** : calcul du Sharpe glissant sur 63 jours pour chaque moteur individuel, avec alerte si un moteur passe sous 0.5. Le Moteur 4 portant 87,0 % du résultat, sa contribution est suivie instrument par instrument (or, dollar-yen, argent). Cela permet de détecter une dégradation structurelle avant que le portefeuille combiné n'en souffre visiblement.
- Re-run mensuel des tests de stress** : régénération complète des trajectoires bootstrap et comparaison aux baselines du présent rapport, chaque premier du mois. Alerte si le CAGR bootstrap moyen dérive de plus de 3 points de pourcentage.
- Validation du slippage réel** : pendant le premier mois de paper-trade, mesurer l'exécution spread réel sur le Moteur 1 (hypothèse du backtest : 15 pb), sur les Moteurs 2 et 3 (hypothèse : 10 pb) et sur le Moteur 4 (hypothèse : 2 pb par côté, sur les trois instruments). Si le slippage réel dépasse l'hypothèse, recalibrer la baseline de performance.
- Plafond d'utilisation de la marge** : configurer le compte broker pour déclencher un délevrage automatique si l'utilisation de marge dépasse 70 % du compte.

8. **Freshness des données macro** : vérifier que le spread de courbe des taux 10Y-2Y et le taux de chômage sont mis à jour automatiquement depuis une source officielle (FRED ou équivalent). Alerte si l'une des séries n'est pas rafraîchie depuis plus de 7 jours.
9. **Audit hebdomadaire des logs d'exécution** : entry et exit time, prix, fees, slippage. Permet de détecter les dérapages d'exécution (brokers qui rejettent les petits ordres ou appliquent du *requote* silencieux).
10. **Procédure de *disaster recovery*** : capacité à liquider l'ensemble des positions en moins de 10 minutes via une *kill switch* manuelle. Cette procédure doit être testée en paper-trade au moins une fois avant le go-live.

16.1 Décisionnaires et responsabilités

Action	Responsable	Fréquence
Re-run stress test	Opérateur quantitatif	Mensuelle
Monitoring drawdown live	Risque	Quotidienne
Audit logs d'exécution	Operations	Hebdomadaire
Refresh données macro	Pipeline automatisé	Horaire
Revalidation des hyperparamètres	Recherche	Semestrielle
Test de <i>kill switch</i>	Operations	Trimestrielle

Idée clé

La règle cardinale : aucun élément de cette check-list ne doit être ignoré, même « temporairement ». Les incidents en production sont presque toujours la conséquence d'un élément « sauté pour aller plus vite ». La discipline de cette check-list *est* la stratégie de risque. Elle constitue la condition contractuelle implicite du déploiement de la stratégie avec capital réel.

A Annexe A — Glossaire des termes techniques

Ce glossaire regroupe les termes techniques utilisés dans le rapport, à destination d'un lecteur qui n'est pas nécessairement familier de la recherche quantitative sur le marché des changes.

Mécanique du signal

Mean reversion (retour à la moyenne)

Stratégie qui mise sur le retour d'un prix vers une valeur de référence après un écart jugé excessif. Sur le marché FX, la valeur de référence peut être un VWAP intraday ou un niveau neutre d'un oscillateur comme le RSI.

Momentum (suivi de tendance)

Stratégie qui mise sur la persistance d'une direction de prix : achat quand le prix monte au-dessus d'une moyenne mobile, vente à la baisse en cas inverse. Exploitation économique des tendances créées par les divergences de politique monétaire et les flux de capitaux.

VWAP (Volume-Weighted Average Price)

Prix moyen pondéré par le volume sur une période donnée. Sur le marché FX, le volume

est typiquement estimé ou forfaitaire et le VWAP se rapproche d'une moyenne temporelle pondérée. Utilisé comme référence de « prix juste » à laquelle le prix tend à revenir pendant les sessions de forte liquidité.

Bollinger Bands (bandes de Bollinger)

Indicateur technique qui entoure un prix (ou sa déviation par rapport à un VWAP) d'une bande supérieure et inférieure calculées à partir de l'écart-type glissant sur une fenêtre. Un toucher de bande est interprété comme un signal de retour à la moyenne.

EMA (Exponential Moving Average)

Moyenne mobile exponentielle qui pondère plus fortement les observations récentes. Un croisement d'une EMA courte au-dessus d'une EMA longue est un signal classique de tendance haussière, et inversement.

RSI (Relative Strength Index)

Oscillateur borné entre 0 et 100 qui mesure la force relative des mouvements récents à la hausse vs. à la baisse. Les seuils classiques sont 30 (sur-vente) et 70 (sur-achat), utilisés comme signaux de retour à la moyenne.

Gestion du portefeuille**Moteur (ou sleeve)**

Sous-stratégie autonome qui produit son propre flux de rendements, combinée avec d'autres moteurs au sein d'un portefeuille agrégé.

Vol targeting (ciblage de volatilité)

Technique qui ajuste dynamiquement le levier appliqué à une stratégie de sorte que la volatilité réalisée du portefeuille reste proche d'une cible annualisée pré-définie. En période de marché calme, le levier augmente ; en période volatile, il diminue automatiquement.

Drawdown

Perte maximale depuis un sommet d'équité, exprimée en pourcentage. Le *Max Drawdown* est la pire perte de la trajectoire complète. C'est la métrique de risque la plus importante pour un investisseur exposé au capital propre.

Sharpe Ratio

Rapport entre le rendement excédentaire annualisé et la volatilité annualisée. Un Sharpe supérieur à 1.0 est généralement considéré comme un bon *edge* ; un Sharpe supérieur à 1.5 est exceptionnel en régime réel.

CAGR (Compound Annual Growth Rate)

Taux de croissance annualisé composé, équivalent à la performance annuelle constante qui aurait produit le rendement total observé sur la période.

Allocation statique

Pondération fixe des moteurs au sein du portefeuille, par opposition à une allocation dynamique qui réagirait aux régimes de marché.

Validation et stress testing**In-sample**

Période de données utilisée pour la conception de la stratégie et le tuning de ses paramètres.

Out-of-sample (hors échantillon)

Période de données *non utilisée* pour la conception, servant à vérifier que la stratégie n'est

pas simplement ajustée au bruit historique. Idéalement, cette période est réservée avant tout design.

Walk-forward

Validation par fenêtres consécutives dans le temps, par exemple année par année. Permet de vérifier que la performance n'est pas concentrée sur une seule fenêtre exceptionnelle.

Bootstrap par blocs mobiles

Technique de ré-échantillonnage statistique qui préserve les autocorrélations locales (intra-mois) tout en cassant la séquence macroéconomique globale. Produit des trajectoires alternatives pour estimer les percentiles de risque.

Look-ahead bias

Erreur méthodologique classique où le backtest utilise de l'information future à l'instant où il prend une décision. Un *edge* qui dépend d'un look-ahead bias est illusoire et disparaît en production.

Scenario replay

Rejeu de la stratégie sur une fenêtre historique nommée (crise Covid, crise GBP 2022, etc.) pour évaluer son comportement dans un régime identifiable.

Exécution**Slippage**

Différence entre le prix théorique utilisé par le backtest et le prix réellement obtenu à l'exécution. Typiquement dû au déplacement du prix pendant la latence d'ordre ou à la largeur du spread bid-ask.

Margin call

Appel de marge du broker lorsque la valeur nette du compte passe sous le seuil requis pour maintenir les positions ouvertes. Déclenche une liquidation forcée si la réserve n'est pas complétée.

Paper-trade

Exécution de la stratégie en environnement réel (données live, latence réelle) mais sans capital réel — utilisé pour valider l'exécution opérationnelle avant le go-live.

Kill switch

Dispositif de liquidation d'urgence permettant de fermer toutes les positions en cas de panne, d'incident, ou de comportement anormal du système.

B Annexe B — Anatomie d'un trade

Pour ancrer la compréhension opérationnelle de la stratégie, cette annexe déroule pas à pas le cheminement qui mène à une entrée réelle sur le Moteur 1 (la composante principale du portefeuille). Les mécaniques des Moteurs 2 et 3 suivent la même logique de filtrage mais sur horizon journalier ; elles sont détaillées dans les sections 5 et 6.

Exemple : entrée long sur EUR-USD le 15 juin 2024 à 10h30 UTC

1. **Calcul du VWAP ancré au jour courant** depuis l'ouverture à 00h00 UTC jusqu'à la minute courante.

2. **Calcul de la déviation** entre le prix de clôture actuel et le VWAP, puis comparaison à la bande inférieure calculée à partir de l'écart-type glissant sur les 80 dernières minutes.
3. Si la déviation est *sous* la bande inférieure, cela signale une sur-vente intraday exploitable.
4. **Filtre session** : l'heure courante 10h30 UTC est bien dans la fenêtre de chevauchement Londres + New York (8h–16h UTC) où la liquidité est maximale.
5. **Filtre macro premier étage** : le spread 10Y–2Y des bons du Trésor américain à cette date est inférieur à 0.5, donc pas de stress cyclique majeur.
6. **Filtre macro second étage** : le taux de chômage américain sur trois mois n'est pas en hausse, donc pas de fin de cycle d'expansion.
7. Les trois filtres sont passants, et la position longue est ouverte.
8. La taille de position est calculée à partir du pool de trésorerie alloué au Moteur 1 (67 % du portefeuille total) multiplié par le levier global courant, divisé par le prix d'entrée.

Conditions de sortie (la première atteinte déclenche la clôture) :

- Retour du prix au-dessus du VWAP (take-profit souple) ;
- Ou stop-loss à -0.5% du prix d'entrée ;
- Ou take-profit dur à $+0.6\%$ du prix d'entrée ;
- Ou durée maximale de détention de 6 heures dépassée ;
- Ou arrêt forcé à 21h00 UTC (fin de session).

— Fin du rapport —

Pour toute question méthodologique, demande d'extension ou analyse complémentaire,

le lecteur est invité à contacter directement l'auteur.

C Sensibilité à l'allocation du trio FX

C.1 La question posée

Le portefeuille final alloue 67 % à MR Macro, 9 % à TS Momentum 3p, 9 % à RSI Daily 3p et 15 % à la sleeve momentum. Cette annexe balaie la répartition *interne au trio FX* — soit, une fois la sleeve momentum servie, les 79/11/11 que forment les poids absolus du trio sur les 85 % restants. Le poids de la sleeve momentum n'est pas balayé ici : il a été tranché séparément, et la section 7 explique pourquoi il a été borné plutôt qu'optimisé. Une question reste ouverte pour un allocateur critique :

La répartition retenue est-elle une pointe isolée sensible au moindre changement de pondération, ou un plateau stable à l'intérieur duquel toute perturbation raisonnable préserve la performance ?

Le balayage est conduit sous la couche de risque production ($\text{target_vol} = 0.37$, $\text{max_leverage} = 31$, DD-cap désactivé) et répond à la question à l'aide de quatre figures et deux tableaux. Le calcul repose sur les séries de rendements journaliers déjà backtestées et mises en cache : aucune nouvelle simulation n'est nécessaire, seulement une recombinaison vectorisée des composantes avec différents vecteurs de poids.

C.2 Méthodologie succincte

Trois grilles de poids sont testées :

- **Huit répartitions nommées** du trio FX — production 79/11/11, pur MR 100/0/0, sans MR 0/50/50, 70/15/15, 60/20/20, 50/25/25, équipondéré 33/33/33, et risk-parity inverse-vol (allocation dynamique des composantes par l'inverse de leur volatilité expansive).
- **Balayage 1D** — w_{MR} varie de 0 % à 100 % par pas de 5 %, avec $w_{TS} = w_{RSI} = (1 - w_{MR})/2$ (21 points).
- **Maillage 2D du simplexe** — grille régulière de pas 0.05 sur le 2-simplexe $\{(w_{MR}, w_{TS}, w_{RSI}) : w_i \geq 0, \sum_i w_i = 1\}$, soit 231 points valides.

Cinq métriques sont calculées par répartition : Sharpe walk-forward (moyenne sur les fenêtres), CAGR, volatilité annualisée, Max Drawdown et Calmar (= CAGR/|Max DD|). Les paramètres de risque et le poids de la sleeve momentum sont fixés, ce qui isole l'effet de la répartition FX.

C.3 Comparaison d'allocations nommées

Tab. 20. Comparaison de 8 répartitions nommées du trio FX sous le régime de risque production (tv = 0.37, ml = 31, DD-cap désactivé), la sleeve or restant à 15 %. Sharpe WF = moyenne sur les fenêtres annuelles glissantes.

Allocation	Sharpe WF	CAGR	Volatilité	Max DD	Calmar
79 / 11 / 11 (production)	1.185	34.62 %	37.27 %	-50.37 %	0.69
100 / 0 / 0 (pur MR)	1.016	26.88 %	37.41 %	-50.56 %	0.53
0 / 50 / 50 (sans MR)	1.030	30.08 %	38.73 %	-59.86 %	0.50
70 / 15 / 15	1.216	36.51 %	37.35 %	-50.01 %	0.73
60 / 20 / 20	1.218	36.99 %	37.43 %	-50.74 %	0.73
50 / 25 / 25	1.208	37.08 %	37.71 %	-53.56 %	0.69
33 / 33 / 33 (équipondéré)	1.162	35.81 %	38.24 %	-56.13 %	0.64
risk-parity	1.210	40.70 %	37.34 %	-41.42 %	0.98

Trois observations saillantes.

- **Le pur MR reste la plus mauvaise des répartitions équilibrées.** Le 100/0/0 donne un Sharpe walk-forward de 1.016 contre 1.185 pour la production, pour un repli équivalent (-50.56 % contre -50.37 %). Le gain des diversifiants se lit donc désormais sur le rendement — 26.88 % de CAGR contre 34.62 % — plutôt que sur le repli, exactement comme la conception le prévoyait.
- **La répartition de production n'est pas l'optimum du balayage.** Plusieurs points voisins font mieux — 70/15/15 atteint 1.216, 60/20/20 1.218, et le meilleur point du simplexe 1.333. L'écart reste de l'ordre du bruit d'estimation, mais il faut le dire : la production occupe un plateau, pas un sommet.
- **Le risk-parity inverse-vol fait aussi bien, avec un repli nettement moindre.** Son Sharpe walk-forward de 1.210 est comparable, pour un Max Drawdown de -41.42 % contre -50.37 %, soit le meilleur Calmar de la table (0.98 contre 0.69). C'est une piste d'amélioration identifiée, non retenue à ce stade pour ne pas introduire une allocation dynamique dans une configuration déjà en cours de validation.




Fig. 25. Comparaison directe de huit répartitions nommées du trio FX, la sleeve momentum restant à 15 %. La répartition de production est mise en évidence en orange.

C.4 Balayage 1D — part MR de 0 % à 100 %

Lecture du plateau. Sur le Sharpe walk-forward, la courbe présente un plateau plat sur une large plage de w_{MR} . Déplacer la production de dix points dans un sens ou dans l'autre ne modifie le Sharpe que de quelques centièmes (1.200 à $w_{MR} = 0.75$, 1.181 à 0.80). C'est la définition opérationnelle d'un plateau robuste.




Fig. 26. Quatre métriques tracées contre la part MR, avec $w_{TS} = w_{RSI} = (1 - w_{MR})/2$. L'étoile orange matérialise le point production. Le Sharpe WF forme un plateau large entre $w_{MR} \approx 0.50$ et $w_{MR} \approx 0.80$ (de 1.18 à 1.22), avec un maximum à 0.60. Le Max Drawdown, lui, est le moins profond autour de $w_{MR} = 0.70$ (−50.0 %) et se creuse vers la seule extrémité sans MR. Le Calmar, qui combine les deux, atteint son maximum autour de $w_{MR} = 0.65$.

C.5 Carte ternaire du simplex complet

Tab. 21. Top-3 et bottom-3 des 231 répartitions du simplex FX (pas de 0.05), classées par Sharpe WF, la sleeve or restant à 15 %. La part moyenne de MR y passe de 35 % en tête à 2 % en queue de classement.

Allocation MR/TS/RSI	Sharpe WF	CAGR	Volatilité	Max DD	Calmar
Top 3					
40/50/10	1.333	44.36 %	37.42 %	-48.12 %	0.92
35/55/10	1.332	44.52 %	37.39 %	-47.68 %	0.93
30/60/10	1.322	44.17 %	37.36 %	-47.23 %	0.94
Bottom 3					
0/5/95	0.864	20.35 %	42.97 %	-59.54 %	0.34
5/0/95	0.860	19.70 %	43.11 %	-60.42 %	0.33
0/0/100	0.846	19.12 %	43.55 %	-61.44 %	0.31

Distance au maximum. Le meilleur point du simplexe atteint un Sharpe walk-forward de 1.333 contre 1.185 pour la répartition de production, soit un écart de 0.148. Cet écart reste très

Carte de chaleur ternaire — Sharpe WF sur le simplex des poids




Fig. 27. Carte de chaleur ternaire du Sharpe WF sur le 2-simplexe complet (231 points). Les sommets correspondent aux répartitions pures du trio FX : 100 % MR, 100 % TS et 100 % RSI, la sleeve momentum restant fixée à 15 % du portefeuille en chacun des points. La zone la plus défavorable est le coin 100 % RSI ; le plateau haut forme une bande large, ce qui est le résultat recherché.

inférieur à la demi-largeur de l'intervalle de confiance bootstrap du Sharpe (section 13), qui est de l'ordre de 0.7. **Déplacer la production vers ce point n'est donc pas statistiquement défendable** : la différence est invisible dans le bruit, et l'y déplacer reviendrait à optimiser sur l'échantillon — exactement ce que le test de sur-ajustement de la section 15 signale déjà.

C.6 Frontière efficiente empirique Vol × CAGR

Lecture de la frontière. Toutes les répartitions se tiennent dans une bande de volatilité étroite : c'est l'effet du ciblage de volatilité, qui ramène chaque combinaison vers la même cible quelle que soit sa composition. Ce qui les distingue est donc le repli et le Sharpe, pas le niveau de risque affiché.

Idée clé

La répartition retenue est un point de plateau, pas une pointe. Le balayage exhaustif du simplexe confirme que : (i) le Sharpe reste élevé sur une large bande autour de la production, (ii) l'écart au meilleur point du balayage est très inférieur à l'intervalle de confiance bootstrap, et (iii) le risk-parity dynamique inverse-vol atteint un Sharpe comparable pour un repli sensiblement plus faible. La sensibilité à la répartition FX est donc faible.




Fig. 28. Scatter de toutes les allocations du simplex dans le plan (Volatilité annualisée, CAGR), coloré par Sharpe WF. La ligne pointillée bourgogne trace la frontière efficiente empirique — l’enveloppe supérieure des points, c’est-à-dire le meilleur CAGR atteignable pour chaque niveau de volatilité. La répartition de production est marquée d’une étoile orange.

Une réserve importante, et elle s’est alourdie : cette annexe ne balaie que la répartition *interne* au trio FX. Or à l’exécution, ces trois moteurs ne produisent ensemble que 13,0 % du résultat — un huitième. La question d’allocation qui pèse réellement sur la performance — le poids de cette sleeve — n’est pas traitée ici. Elle l’a été autrement : son optimum apparent se trouvait à la borne du domaine testé, et le test de sur-ajustement appliqué à cette grille échoue (section 13), ce qui a conduit à ramener le poids de 20 % à 15 %.

D Principes méthodologiques du *robustness report*

Cet appendice détaille les principes mathématiques et les références académiques des tests statistiques appliqués en section 13. Les formules ci-dessous sont implémentées dans les modules `framework.robustness` et `framework.statistical_testing` du projet.

D.1 Le problème général — pourquoi un Sharpe ponctuel est insuffisant

Un rapport de *backtest* standard reporte typiquement trois statistiques ponctuelles : Sharpe, CAGR, Max Drawdown. Ces estimateurs souffrent de trois biais qui menacent la validité de l'inférence.

Biais d'échantillon (Lo 2002). Sur une série iid de T observations, l'écart-type de l'estimateur du Sharpe vaut approximativement :

$$\sigma(\widehat{\text{SR}}) \approx \sqrt{\frac{1 + 0.5 \widehat{\text{SR}}^2}{T}} \quad (1)$$

Sur les 8.5 ans de données journalières de ce portefeuille ($T = 2146$), cette formule donne un écart-type annualisé de 0.34 sur l'estimateur : un Sharpe vrai nul peut produire un Sharpe observé de cet ordre par pure chance. Le bruit d'estimation est loin d'être négligeable, et c'est ce qui explique la largeur de l'intervalle de confiance publié pour le Sharpe (tableau 18).

Biais de sélection (Bailey–López de Prado 2014). Lorsqu'on teste N configurations et qu'on rapporte le meilleur résultat, l'espérance du maximum sous hypothèse nulle est approximativement :

$$\mathbb{E} \left[\max_{i \leq N} \text{SR}_i \right] \approx \sqrt{2 \ln N} \quad (2)$$

pour des Sharpes iid $\mathcal{N}(0, 1)$. Tester 1000 configurations sur une stratégie sans *edge* produit mécaniquement un Sharpe top de ≈ 3.72 .

Dépendance temporelle. Les rendements financiers ne sont pas iid : les périodes de volatilité élevée s'enchaînent (effets ARCH), les *mean reversions* opèrent à des échelles variables, les régimes de marché durent des semaines ou des mois. Ignorer cette dépendance sous-estime la variance des estimateurs et surestime la significativité des tests paramétriques.

D.2 Block bootstrap stationnaire (Politis–Romano 1994)

Politis, D.N., Romano, J.P. (1994). *The Stationary Bootstrap*. Journal of the American Statistical Association, 89(428), pp. 1303–1313.

Principe. Pour estimer la distribution d'échantillonnage d'une statistique sur une série $\{r_1, r_2, \dots, r_T\}$, on construit un ré-échantillon en concaténant des *blocs* d'observations consécutives. La longueur de chaque bloc est tirée selon une loi géométrique de moyenne L (paramètre `block_len_mean` = 20 dans le rapport Apogee) ; le point de départ est choisi uniformément.

Pourquoi une longueur géométrique ? Contrairement au bootstrap par blocs fixes de Künsch (1989), la longueur géométrique rend la série ré-échantillonnée *stationnaire* : chaque point bootstrap a la même distribution marginale. On préserve ainsi les propriétés du second ordre (autocorrélation, volatility clustering) jusqu'à l'échelle L sans introduire de non-stationnarité artificielle aux bords des blocs.

Algorithme.

$$i_{k+1} = \begin{cases} \sim \text{Uniforme}(\{1, \dots, T\}) & \text{avec probabilité } p = 1/L \\ (i_k + 1) \bmod T & \text{sinon} \end{cases} \quad (3)$$

avec i_1 tiré uniformément. Les indices $\{i_1, \dots, i_T\}$ permettent de construire le ré-échantillon $\{r_{i_1}, \dots, r_{i_T}\}$ sur lequel on calcule la statistique d'intérêt. Le processus est répété n_{boot} fois

(3000 dans notre cas) et les quantiles empiriques de la distribution donnent les intervalles de confiance.

Choix de L . Hall, Horowitz et Jing (1995) recommandent $L \propto T^{1/3}$. Pour $T = 2146$ barres journalières, cette règle donne $L \approx 13$. Notre choix de $L = 20$ est légèrement conservateur, ce qui donne des intervalles de confiance légèrement plus larges et donc plus prudents.

D.3 Probabilistic Sharpe Ratio (Bailey–López de Prado 2012)

Bailey, D.H., López de Prado, M. (2012). *The Sharpe Ratio Efficient Frontier*. Journal of Risk, 15(2), pp. 3–44.

Le PSR répond à la question : *quelle est la probabilité que le vrai Sharpe soit supérieur à un benchmark SR^* ?*, en tenant compte explicitement de la **non-normalité** de la distribution des rendements (skewness γ_3 et kurtosis γ_4).

$$PSR(SR^*) = \Phi \left(\frac{(\widehat{SR} - SR^*) \sqrt{T-1}}{\sqrt{1 - \gamma_3 \widehat{SR} + \frac{\gamma_4-1}{4} \widehat{SR}^2}} \right) \quad (4)$$

où Φ est la fonction de répartition normale standard. La formule généralise le test de Jobson–Korkie (1981) en incorporant les moments d'ordre 3 et 4. Le PSR est le *premier* filtre de significativité pour une stratégie sans sélection multiple : si $PSR(0) < 0.95$, la stratégie n'a pas d'*edge* distinguable du bruit.

D.4 Deflated Sharpe Ratio (Bailey–López de Prado 2014)

Bailey, D.H., López de Prado, M. (2014). *The Deflated Sharpe Ratio : Correcting for Selection Bias, Backtest Overfitting and Non-Normality*. Journal of Portfolio Management, 40(5), pp. 94–107.

Le DSR est un PSR dont le *benchmark* est l'**espérance du maximum Sharpe sous hypothèse nulle**, calculée explicitement à partir du nombre d'essais N et de la variance du vecteur de Sharpes testés. L'approximation vient de la théorie des valeurs extrêmes (expansion de Fisher–Tippett) :

$$\mathbb{E} \left[\max_{i \leq N} SR_i \right] \approx \sqrt{\text{Var}[\widehat{SR}]} \left[(1 - \gamma) \Phi^{-1} \left(1 - \frac{1}{N} \right) + \gamma \Phi^{-1} \left(1 - \frac{1}{N^e} \right) \right] \quad (5)$$

où $\gamma = 0.5772 \dots$ est la constante d'Euler–Mascheroni et Φ^{-1} est l'inverse de la distribution normale. Le DSR est ensuite le PSR calculé avec ce seuil comme *benchmark* :

$$DSR = PSR(SR^* = \mathbb{E}[\max SR \mid N]) \quad (6)$$

Exemple numérique Apogee. $N = 382$ essais (les configurations distinctes du registre d'essais du projet), $\widehat{\sigma}[\widehat{SR}] = 0.062$ entre les allocations rivales, ce qui donne $\mathbb{E}[\max SR \mid N = 382] = 0.185$. Le Sharpe observé $\widehat{SR} = 0.99$ dépasse ce seuil d'un facteur 5, d'où $DSR = 1.000$.

La limite de ce test, et où elle se voit. Le seuil dépend beaucoup moins de N (il croît en $\sqrt{2 \ln N}$) que de la *dispersion* des essais rivaux. Ici les 382 essais sont des variantes d'un même portefeuille : leur dispersion est faible, le seuil est bas, et le verdict favorable est en partie mécanique. Appliquée aux 21 instruments du criblage, dont les Sharpe s'étalent de -1.05 à $+0.78$, la même formule donne $\mathbb{E}[\max SR] = 2.89$ — seuil qu'aucun des trois instruments retenus ne franchit. Le DSR valide l'assemblage, pas la sélection des composants.

D.5 Haircut Sharpe Ratio (Harvey–Liu 2015)

Harvey, C.R., Liu, Y. (2015). *Backtesting*. Journal of Portfolio Management, 42(1), pp. 13–28.

Le *Haircut Sharpe* convertit le Sharpe en t-statistic, corrige la p-value pour tests multiples, puis reconvertit en Sharpe « *haircut* » via l'inverse. Le *pipeline* en cinq étapes est :

1. Calcul du t-stat : $t_{\text{obs}} = \widehat{\text{SR}} \sqrt{T-1}$
2. Calcul de la p-value brute via la fonction de survie de Student-t : $p_{\text{raw}} = P(T > t_{\text{obs}})$
3. Correction pour tests multiples : $p_{\text{adj}} = \text{correction}(p_{\text{raw}}, N)$
4. Inversion : $t_{\text{adj}} = t^{-1}(1 - p_{\text{adj}})$
5. Reconversion en Sharpe : $\text{SR}_{\text{haircut}} = t_{\text{adj}} / \sqrt{T-1}$

Trois schémas de correction sont disponibles :

- **Bonferroni** : $p_{\text{adj}} = \min(p_{\text{raw}} \cdot N, 1)$. Le plus simple, le plus conservateur. Hypothèse : tests strictement indépendants.
- **Holm** : séquentiel, moins conservateur que Bonferroni. Pour le top-1, coïncide avec Bonferroni.
- **BHY (Benjamini–Hochberg–Yekutieli)** : contrôle le *False Discovery Rate* au lieu du FWER. **Par défaut dans notre module.** Plus permissif que Bonferroni sous corrélation arbitraire des tests. Formule pour le top-1 :

$$p_{\text{adj}}^{\text{BHY}} = p_{\text{raw}} \cdot N \cdot c(N) \quad \text{avec} \quad c(N) = \sum_{i=1}^N \frac{1}{i} \quad (7)$$

où $c(N)$ est le N -ème nombre harmonique.

Ratio de survie. La quantité utile pour l'investisseur est :

$$\text{Haircut Ratio} = \frac{\text{SR}_{\text{haircut}}}{\widehat{\text{SR}}} \quad (8)$$

qui représente la fraction de l'*edge* qui survit à la correction. Un ratio supérieur à 80 % est un bon signe — l'*edge* est grand relativement à la variance d'estimation et les corrections multi-test ont peu d'emprise. Pour le portefeuille Apogee, le ratio BHY est 96.11 % (tableau 16).

D.6 Minimum Backtest Length (Bailey et al. 2014)

Bailey, D.H., Borwein, J.M., López de Prado, M., Zhu, Q.J. (2014). *Pseudo-Mathematics and Financial Charlatanism : The Effects of Backtest Overfitting on Out-of-Sample Performance*. Notices of the American Mathematical Society, 61(5), pp. 458–471.

Le MinBTL répond à la question : *combien d'années de données sont nécessaires pour qu'un Sharpe cible soit statistiquement distinguable du fruit de N essais multiples ?*

$$\text{MinBTL}(\text{SR}, N) \approx \frac{2 \ln N}{\text{SR}^2} \quad (\text{en années}) \quad (9)$$

Exemples numériques.

- SR cible = 1.0, $N = 100$ essais : MinBTL = 9.2 ans.
- SR cible = 1.0, $N = 1000$ essais : MinBTL = 13.8 ans.
- SR cible = 2.0, $N = 1000$ essais : MinBTL = 3.5 ans.

Utilisation comme *power calculation a priori*. Avant de lancer un *grid search* massif, le MinBTL répond à : *mon historique est-il assez long pour que le grid search produise un résultat statistiquement défendable ?*. Si on veut tester 1000 configurations et qu'on a 5 ans de données, le seul Sharpe qu'on peut espérer « prouver » est supérieur à $\sqrt{2 \ln 1000 / 5} \approx 1.66$. Tout ce qu'on trouvera en-dessous de ce seuil est susceptible d'être du bruit.

Pour le portefeuille Apogee, le MinBTL affiché est 12.25 ans pour $SR = 0.99$ avec $N = 382$ essais. On dispose de 8.5 ans : **le minimum statistique n'est pas atteint**, et il ne le sera que par accumulation de temps réel, pas par un traitement supplémentaire des mêmes données.

D.7 Probability of Backtest Overfitting via CSCV (Bailey et al. 2015)

Bailey, D.H., Borwein, J.M., López de Prado, M., Zhu, Q.J. (2015). *The Probability of Backtest Overfitting*. Journal of Computational Finance, 20(4), pp. 39–69.

Le PBO est la probabilité que le **vainqueur in-sample** termine **sous la médiane out-of-sample**. Un PBO supérieur à 0.5 indique un *overfit* manifeste ; inférieur à 0.5 indique une stratégie robuste.

Algorithme CSCV (Combinatorially Symmetric Cross-Validation). En entrée : une matrice $M \in \mathbb{R}^{T \times n_{\text{configs}}}$ des rendements par configuration par barre.

1. **Partition** : découper les T lignes en S blocs contigus de taille T/S (avec $S = 16$ par défaut).
2. **Énumération combinatoire** : énumérer les $\binom{S}{S/2}$ manières de choisir $S/2$ blocs pour l'in-sample et $S/2$ blocs pour l'out-of-sample. Pour $S = 16$, cela donne $\binom{16}{8} = 12\,870$ partitions.
3. **Pour chaque partition** :
 - a) Calculer le Sharpe IS de chaque configuration sur les $S/2$ blocs in-sample.
 - b) Identifier $n^* = \arg \max(\text{Sharpe IS})$, le vainqueur in-sample.
 - c) Calculer le rang OOS de n^* sur les $S/2$ blocs out-of-sample.
 - d) Convertir le rang en logit : $\text{logit} = \ln(w/(1-w))$ avec $w = \text{rang}/(N+1)$.
4. **Agrégation** : $\text{PBO} = \text{fraction de partitions où logit} < 0$.

Pourquoi « symétrique » ? Par construction, chaque bloc apparaît exactement $\binom{S-1}{S/2-1}$ fois en IS et autant en OOS — ce qui élimine le biais de découpage.

Interprétation du logit.

- $\text{logit} \gg 0$: le vainqueur IS est au sommet du classement OOS (excellent signe).
- $\text{logit} \approx 0$: le vainqueur IS est à la médiane OOS (*overfitting* partiel).
- $\text{logit} < 0$: le vainqueur IS tombe sous la médiane OOS (*overfitting* manifeste).

Pour Apogee, $\text{PBO} = 0.649$: dans 64,9 % des partitions, l'allocation la mieux classée in-sample retombe sous la médiane hors échantillon. C'est *au-dessus* du seuil critique de 0.5 — ce test échoue, et c'est lui qui a fait ramener le poids de la sleeve momentum de 20 % à 15 % (section 13). Le PBO est mesuré sur la grille d'allocations réellement parcourue ; les éditions antérieures de ce rapport le calculaient sur la matrice des quatre *sleeves* et annonçaient 0.305, une valeur qui répondait à une question jamais posée dans ce projet.

Limite. Le CSCV suppose que les configurations sont échantillonnées du même « univers ». Si on a $N = 2$ configurations très différentes, le PBO est peu informatif. Il devient significatif à partir de $N \geq 10$.

D.8 Hansen SPA (2005) et Romano–Wolf StepM (2005)

White, H. (2000). *A Reality Check for Data Snooping*. *Econometrica*, 68(5), pp. 1097–1126.
 Hansen, P.R. (2005). *A Test for Superior Predictive Ability*. *Journal of Business & Economic Statistics*, 23(4), pp. 365–380.
 Romano, J.P., Wolf, M. (2005). *Stepwise Multiple Testing as Formalized Data Snooping*. *Econometrica*, 73(4), pp. 1237–1282.

Tous trois répondent à la question : *est-ce qu’au moins une stratégie d’un univers de N candidats bat significativement un benchmark après correction complète du data snooping ?*

Hansen SPA (Superior Predictive Ability). Variante raffinée du *Reality Check* de White. Le RC souffre d’être trop conservateur quand le *sweep* contient des stratégies manifestement mauvaises (elles tirent la distribution nulle vers le bas). Hansen introduit un *re-centering* qui exclut ces stratégies du calcul de la distribution sous H_0 . Trois p-values sont retournées (*lower*, *consistent*, *upper*) correspondant à trois estimateurs différents — la version *consistent* est celle utilisée en pratique.

Romano–Wolf StepM. Approche *stepwise* qui rend non pas une p-value unique mais un **ensemble** de stratégies qui dominent le *benchmark* avec FWER (Family-Wise Error Rate) contrôlé à α . Préférable à SPA quand on veut identifier *lesquelles* des N stratégies sont significatives, pas seulement s’il en existe au moins une.

Implémentation. Wrappers autour de `arch.bootstrap.SPA` et `arch.bootstrap.StepM` (paquet `arch` de Kevin Sheppard, licence NCSA). Voir `framework.statistical_testing.reality_check_via_arch` et `stepm_romano_wolf`.

D.9 Stratégie de combinaison — quelle hiérarchie de tests ?

Les tests implémentés dans `framework.robustness` ne sont pas tous appliqués au même stade du *workflow*. Voici la hiérarchie recommandée :

Stade 1 — Backtest unique, zéro data snooping. Bootstrap CI sur les 14 métriques, PSR vs 0, *equity fan chart* visuel. *Verdict* : la stratégie a-t-elle un edge observable ?

Stade 2 — Après grid search / optimisation de paramètres. DSR (avec N réel des *trials*), *Haircut Sharpe* (BHY recommandé), MinBTL (*power calculation*), PBO via CSCV. *Verdict* : l’edge survit-il à la correction multi-test ?

Stade 3 — Sélection finale parmi N candidats. Hansen SPA, Romano–Wolf StepM, CPCV (*Combinatorial Purged CV*, López de Prado 2018 ch. 12 — à intégrer dans une itération future). *Verdict* : la meilleure bat-elle un benchmark après correction globale ?

Stade 4 — Validation opérationnelle. Monte Carlo sur les *trades* (*sequence risk*), walk-forward multi-horizon, *paper trading* ≥ 3 mois, *stress test* scénarios (2008 GFC, 2020 Covid, 2022 UK gilts, ...). *Verdict* : la stratégie tient-elle en conditions réelles ?

Application au portefeuille Apogee. Les stades 1, 2 et 3 sont documentés dans la section 13 avec un *caveat* sur l’interprétation SPA vs DSR. Le stade 4 est couvert par la section 12 (bootstrap historique), la section 14 (rejeu de scénarios historiques) et la section 16 (checklist *paper-trade* et déploiement). Une stratégie qui franchit les quatre stades avant capital réel est statistiquement défendable. **Ce portefeuille n’en fait pas partie** : au stade 2, deux tests sur six échouent — la probabilité de sur-ajustement et la longueur minimale de *backtest*

(section 15). Le stade 4 n'est pas encore consommé : le *paper-trade* reste à faire, et c'est la seule validation de ce portefeuille qui soit authentiquement pré-engagée.